

1.3 Probleme rezolvate de seminar

1.3.1 Diferențiere multivariabilă

Problema 1. Fie funcțiile $f: \mathbb{R}^3 \rightarrow \mathbb{R}$ și $g: \mathbb{R}^2 \rightarrow \mathbb{R}$ definite de:

$$f(x) = x_1^3 x_2 + 2x_3^2 x_1 - x_2 x_3, \\ g(x) = e^{x_1 - x_2} + e^{2x_1 - 1} - e^{2x_2 - 2}.$$

- (i) Să se determine expresiile gradientilor $\nabla f(x)$, $\nabla g(x)$.
(ii) Să se determine expresiile Hessianelor $\nabla^2 f(x)$, $\nabla^2 g(x)$.

Rezolvare. Pentru o funcție diferențiabilă de 2 ori $f: \mathbb{R}^n \rightarrow \mathbb{R}$, reamintim definițiile gradientului și Hessienei:

$$\nabla f(x) = \begin{bmatrix} \frac{\partial f(x)}{\partial x_1} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{bmatrix}, \quad \nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f(x)}{\partial x_1^2} & \cdots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 f(x)}{\partial x_n^2} \end{bmatrix}.$$

- (i) Expresiile gradientilor funcțiilor din enunț au forma:

$$\nabla f(x) = \begin{bmatrix} 3x_1^2 x_2 + 2x_3^2 \\ x_1^3 - x_3 \\ 4x_3 x_1 - x_2 \end{bmatrix}, \quad \nabla g(x) = \begin{bmatrix} e^{x_1 - x_2} + 2e^{2x_1 - 1} \\ -e^{x_1 - x_2} - 2e^{2x_2 - 2} \end{bmatrix}.$$

- (ii) Expresiile Hessianelor funcțiilor din enunț au forma:

$$\nabla^2 f(x) = \begin{bmatrix} 6x_1 x_2 & 3x_1^2 & 4x_3 \\ 3x_1^2 & 0 & -1 \\ 4x_3 & -1 & 4x_1 \end{bmatrix}, \\ \nabla^2 g(x) = \begin{bmatrix} e^{x_1 - x_2} + 4e^{2x_1 - 1} & -e^{x_1 - x_2} \\ -e^{x_1 - x_2} & e^{x_1 - x_2} - 4e^{2x_2 - 2} \end{bmatrix}.$$

Problema 2. Fie funcția multidimensională $h: \mathbb{R}^3 \rightarrow \mathbb{R}^2$,

$$h(x) = \begin{bmatrix} x_2^2 + x_3 \\ x_1^2 + x_2 \end{bmatrix}.$$

- (i) Determinați expresia Jacobianului $\nabla h(x)$.

- (ii) Arătați că, în orice vector $x \in \mathbb{R}^3$, Jacobianul calculat are liniile linear independente.

Rezolvare. (i) Din definiția Jacobianului pentru o funcție $h: \mathbb{R}^3 \rightarrow \mathbb{R}^2$, i.e. $\nabla h(x) = \begin{bmatrix} \frac{\partial h_1(x)}{\partial x_1} & \frac{\partial h_1(x)}{\partial x_2} & \frac{\partial h_1(x)}{\partial x_3} \\ \frac{\partial h_2(x)}{\partial x_1} & \frac{\partial h_2(x)}{\partial x_2} & \frac{\partial h_2(x)}{\partial x_3} \end{bmatrix}$, avem $\nabla h(x) = \begin{bmatrix} 0 & 2x_2 & 1 \\ 2x_1 & 1 & 0 \end{bmatrix}$.

- (ii) Din definiția proprietății de linear independență avem: doi vectori $u, v \in \mathbb{R}^n$ sunt linear independenți dacă nu există un scalar $\alpha \neq 0$ astfel încât $u = \alpha v$. Această proprietate este evidentă observând că egalitatea:

$$\begin{bmatrix} 2x_1 \\ 1 \\ 0 \end{bmatrix} = \alpha \begin{bmatrix} 0 \\ 2x_2 \\ 1 \end{bmatrix}$$

nu poate avea loc dacă $\alpha \neq 0$.

1.3.2 Probleme de optimizare generale

Problema 3. Fie următoarea problemă de optimizare:

$$\min_{x \in \mathbb{R}^2} x_1^3 + x_2^3 \\ \text{s.t.: } (x_1 + x_2)^2 \leq 0, \\ x_1 x_2^3 = -1.$$

- (i) Să se precizeze care sunt constrângerile de egalitate și care sunt cele de inegalitate.
(ii) Să se determine analitic punctul de optim și valoarea optimă.

Rezolvare. (i) Se observă că inegalitatea $(x_1 + x_2)^2 \leq 0$ este echivalentă cu $(x_1 + x_2)^2 = 0$. Concluzionăm că nu există constrângeri de inegalitate și avem două constrângeri de egalitate: $h_1(x) = x_1 + x_2 = 0$ și $h_2(x) = x_1 x_2^3 + 1 = 0$.

(ii) Din punctul (i) rezultă că $x_1 + x_2 = 0$ și făcând sistem cu cea de-a doua constrângere, concluzionăm că mulțimea fezabilă este formată din două puncte, anume $(x_1, x_2) = (1, -1)$ și $(x_1, x_2) = (-1, 1)$. Punctele de optim global vor fi $(x_1^*, x_2^*) = (1, -1)$ și $(x_1^*, x_2^*) = (-1, 1)$, din moment ce valoarea optimă $f^* = 0$ este aceeași pentru ambele.

Problema 4. Fie funcția $f: \Delta_n \rightarrow x, f(x) = \ln x^T A x$, unde Δ_n este o mulțime, numită mulțimea simplex, și este dată de $\Delta_n = \{x \in \mathbb{R}^n :$

$\sum_{i=1}^n x_i = 1, x_i \geq 0 \quad \forall i = 1, \dots, n$, $A \in \mathbb{R}^{n \times n}$ este o matrice simetrică și pozitivă (i.e. toate elementele matricei sunt ne-negative).

- (i) Să se determine expresia gradientului $\nabla f(x)$ și a Hessienei $\nabla^2 f(x)$.
(ii) Să se determine constanta Lipschitz a gradientului funcției f .

Rezolvare: (i) Prin calcule simple, obținem că expresia gradientului este dată de $\nabla f(x) = \frac{2Ax}{x^T Ax}$, iar a hessienei $\nabla^2 f(x) = \frac{2Ax^T Ax - (2Ax)(2Ax)^T}{(x^T Ax)^2} = \frac{2A}{x^T Ax} - \frac{4Ax}{x^T Ax} \left(\frac{Ax}{x^T Ax} \right)^T$.

- (ii) Gradientul este continuu în sens Lipschitz dacă următoarea inegalitate are loc:

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L \|x - y\|_2 \quad \forall x, y \in \Delta_n.$$

Echivalent, această proprietate se exprimă și în termenii matricei Hessiene:

$$\|\nabla^2 f(x)\|_2 \leq L \quad \forall x \in \Delta_n.$$

Observăm că matricea $\frac{(2Ax)(2Ax)^T}{(x^T Ax)^2}$ este pozitiv semidefinită, de aceea avem următoarea mărginire a noimei Hessienei:

$$\|\nabla^2 f(x)\| \leq \left\| \frac{2A}{x^T Ax} \right\| \quad \forall x \in \Delta_n.$$

Mai mult, observăm că

$$\min_{x \in \Delta_n} x^T A x = \min_{x \in \Delta_n} \sum_{i,j} A_{ij} x_i x_j \geq \min_{x \in \Delta_n} \left(\min_i A_{ii} \right) \|x\|^2 = \frac{1}{N} \left(\min_i A_{ii} \right).$$

De aici obținem o aproximare a constantei Lipschitz corespunzătoare gradientului funcției din enunț:

$$\|\nabla^2 f(x)\| \leq N \left\| \frac{2A}{\min_i A_{ii}} \right\| = L.$$

Problema 5. Fie $P \in \mathbb{R}^{n \times n}$ o matrice simetrică și inversabilă. Să se arate că funcția pătratică:

$$f(x) = \frac{1}{2} x^T P x + x^T b$$

are valoare minimă (i.e. este mărginită inferior) dacă și numai dacă $P \succeq 0$ (i.e. este pozitiv semidefinită). Mai mult, în cazul în care este mărginită, arătați că punctul de minim x^* este unic și determinat de expresia $x^* = -P^{-1}b$.

Rezolvare. Observăm că

$$\frac{1}{2} (x + P^{-1}b)^T P (x + P^{-1}b) = \frac{1}{2} x^T P x + b^T x + \frac{1}{2} b^T P^{-1}b.$$

De aici rezultă,

$$f(x) = \frac{1}{2} x^T P x + b^T x = \frac{1}{2} (x + P^{-1}b)^T P (x + P^{-1}b) - \frac{1}{2} b^T P^{-1}b.$$

Presupunem că P are o valoare proprie negativă, e.g. $-\lambda$ (unde $\lambda > 0$) și notăm vectorul propriu asociat valorii proprii negative cu u . Atunci, pentru orice $\alpha \in \mathbb{R}, \alpha \neq 0$, considerând $x = \alpha u - P^{-1}b$ și ținând cont de relația $Pu = -\lambda u$, avem:

$$f(x) = \frac{1}{2} (x + P^{-1}b)^T P (x + P^{-1}b) - \frac{1}{2} b^T P^{-1}b \\ = \frac{1}{2} \alpha u^T P \alpha u - \frac{1}{2} b^T P^{-1}b \\ = -\frac{1}{2} \lambda \alpha^2 \|u\|_2^2 - \frac{1}{2} b^T P^{-1}b.$$

În final, observăm că $\lambda > 0$ și avem libertatea de a alege α oricât de mare, de unde rezultă că funcția nu are minimum (i.e. minimum se atinge la $-\infty$). Pentru ca funcția să aibă minimum este necesar ca $P \succeq 0$. Pentru a arăta ultima parte a rezultatului, din reformularea lui $f(x)$ anterioară avem:

$$f(x) = \frac{1}{2} (x + P^{-1}b)^T P (x + P^{-1}b) - \frac{1}{2} b^T P^{-1}b.$$

Observăm că $\frac{1}{2} (x + P^{-1}b)^T P (x + P^{-1}b) \geq 0$, deci minimul funcției se atinge atunci când $x + P^{-1}b = 0$.

Problema 6. Fie problema de optimizare :

$$\min_{x \in \mathbb{R}^n} f(x) \quad \left(= \frac{c^T x + d}{e^T x + f} \right) \\ \text{s.t. } Gx \leq h, \quad Ax = b,$$

cu domf(x) = $\{x \in \mathbb{R}^n : e^T x + f > 0\}$. Arătați că această problemă poate fi adusă la forma de programare liniară.

Rezolvare. Notăm $u(x) = c^T x + f > 0$. Împărțind relația prin $u(x)$, aceasta devine: $\frac{c^T x}{u(x)} + f \frac{1}{u(x)} = 1 > 0$. De asemenea, folosim notația $y(x) = \frac{c^T x}{u(x)} \in \mathbb{R}^n$ și $z(x) = \frac{1}{u(x)} \in \mathbb{R}$. Reformulând funcția obiectiv avem:

$$f(x) = \frac{c^T x + d}{u(x)} = c^T \frac{x}{u(x)} + d \frac{1}{u(x)} = c^T y(x) + dz(x).$$

Folosind schimbarea de variabilă precedentă, putem aduce problema de minimizare după x la una ce presupune minimizarea după $y(x)$ și $z(x)$. Pentru a schimba variabila constrângerilor, împărțim prin u ultimele două seturi de egalități/inegalități. Astfel, obținem un LP:

$$\begin{aligned} \min_{y \in \mathbb{R}^n, z \in \mathbb{R}} \quad & c^T y + dz \\ \text{s.l.:} \quad & c^T y + fz = 1, \quad Ay = bz \\ & Gy \leq hz. \end{aligned}$$

Problema 7. Fie următoarea problemă de optimizare:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} \quad & 2x_1^2 + x_2^2 - x_1 x_2 \\ \text{s.l.:} \quad & 2^{x^T x - 1} \leq 2, \quad (a^T x - b)^2 \leq 0 \\ & 5^{|x_1|} \leq 1, \quad 3^{x_1 + x_2} = 1, \end{aligned}$$

unde $a \in \mathbb{R}^2$ și $b \in \mathbb{R}$ sunt dați. Să se arate că toate funcțiile care descriu problema de optimizare sunt fie liniare, fie pătrărice. Să se precizeze care sunt constrângerile de egalitate și care sunt cele de inegalitate.

Rezolvare. Se observă că funcția obiectiv $f(x) = 2x_1^2 + x_2^2 - x_1 x_2$ este pătratică, i.e.

$$f(x) = \frac{1}{2} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^T \begin{bmatrix} 4 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

Constrângerea $2^{x^T x - 1} \leq 2$ este echivalentă cu $x^T x - 1 \leq 1$, i.e. $x^T x \leq 2$. Deci prima constrângere este una de inegalitate descrisă de o funcție pătratică $g_1(x) = x^T x - 2 \leq 0$. Constrângerea $(a^T x - b)^2 \leq 0$ este echivalentă cu $a^T x - b = 0$. Deci a doua constrângere este de egalitate descrisă de o funcție liniară $h_1(x) = a^T x - b = 0$.

Constrângerea $5^{|x_1| - 1} \leq 1$ este echivalentă cu $|x_1| - 1 \leq 0$. Deci a treia constrângere este de inegalitate, descrisă de două funcții liniare $g_2(x) = x_1 - 0 \leq 0$ și $g_3(x) = -x_1 - 1 \leq 0$. Constrângerea $3^{x_1 + x_2} = 1$ este echivalentă cu $x_1 + x_2 = 0$. Deci a patra constrângere este de egalitate, descrisă de o funcție liniară $h_2(x) = x_1 + x_2 = 0$.

Problema 8. O funcție se numește *monomială* dacă se prezintă sub forma:

$$f(x) = cx_1^{a_1} x_2^{a_2} \dots x_n^{a_n},$$

în care $c > 0$, $a_i \in \mathbb{R}$ și $x \in \mathbb{R}_+^n$, i.e. $x_i > 0$ pentru orice $i = 1, \dots, n$. Considerând problema de programare geometrică:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{s.l.:} \quad & g_i(x) \leq 1 \quad \forall i = 1, \dots, m \\ & h_i(x) = 1 \quad \forall i = 1, \dots, p, \end{aligned}$$

cu f_i și h_i funcții monomiale. Arătați că o astfel de problemă de programare geometrică poate fi scrisă sub forma unui LP.

Rezolvare. Din teoria optimizării știm că punctul de optim al unei probleme de optimizare cu funcția obiectiv $f(x)$, este același cu cel al problemei cu funcția obiectiv $\log f(x)$. Într-adevăr, în cazul neconstrâns condițiile suficiente de optimalitate pentru problema originală (cu funcția obiectiv $f(x)$) sunt $\nabla f(x^*) = 0$. Observăm că pentru cazul compunerii cu funcția logaritm (cu funcția obiectiv $\log f(x)$) condițiile de optimalitate se transformă în $\frac{\nabla f(x^*)}{f(x^*)} = 0$, sau echivalent în $\nabla f(x^*) = 0$. Precizăm că pentru cazul constrâns are loc o echivalență logaritmică similară, i.e. având problema originală:

$$\begin{cases} \min_{x \in \mathbb{R}^n} & cx_1^{a_1} x_2^{a_2} \dots x_n^{a_n} \\ \text{s.l.:} & c_i x_1^{b_i^1} x_2^{b_i^2} \dots x_n^{b_i^n} \leq 1 \quad \forall i = 1, \dots, m \\ & e_j x_1^{d_j^1} x_2^{d_j^2} \dots x_n^{d_j^n} = 1 \quad \forall j = 1, \dots, p, \end{cases}$$

compunând funcția obiectiv și constrângerile cu funcția logaritm, obținem o problemă de optimizare cu același punct de optim:

$$\begin{cases} \min_{x \in \mathbb{R}^n} & \log(cx_1^{a_1} x_2^{a_2} \dots x_n^{a_n}) \\ \text{s.l.:} & \log(c_i x_1^{b_i^1} x_2^{b_i^2} \dots x_n^{b_i^n}) \leq 0 \quad \forall i = 1, \dots, m \\ & \log(e_j x_1^{d_j^1} x_2^{d_j^2} \dots x_n^{d_j^n}) = 0 \quad \forall j = 1, \dots, p. \end{cases}$$

Folosind schimbarea de variabilă $\log x_i = y_i$, observăm următoarea reformularea liniară a unei funcții monomiale:

$$f(x) = \log(cx_1^{a_1} \dots x_n^{a_n}) = \log c + \sum_{i=1}^n a_i \log x_i = \log c + \sum_{i=1}^n a_i y_i.$$

Astfel, rezultă o formă LP a problemei în variabila y .

Problema 9. Fie funcția pătratică $f: \mathbb{R}^2 \rightarrow \mathbb{R}$, $f(x) = x_1^2 - x_2^2 + x_1 x_2$. Să se arate că funcția f are gradient Lipschitz în raport cu norma Euclidiană, i.e. există $L > 0$ astfel încât:

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L\|x - y\|_2, \quad \forall x, y \in \mathbb{R}^2.$$

și să se determine constanta Lipschitz corespunzătoare.

Rezolvare. Remarcăm că funcția f se poate formula ca $f(x) = \frac{1}{2} x^T Q x$, unde $Q = \begin{bmatrix} 2 & 1 \\ 1 & -2 \end{bmatrix}$. Verificând relația de continuitate Lipschitz avem:

$$\|Qx - Qy\|_2 = \|Q(x - y)\|_2 \leq \|Q\|_2 \|x - y\|_2, \quad \forall x, y \in \mathbb{R}^2.$$

Inegalitatea reiese din definiția normei matriciale induse. Evident, constanta Lipschitz este dată de $L = \|Q\|_2 = \lambda_{\max}(Q)$.

1.4 Probleme propuse

Problema 1. Să se arate că problema de optimizare (1.1) este problemă pătratică (QP). Evidențiază matricea Hessiană și precizați dacă este sau nu pozitiv definită.

Problema 2. Fie funcția neliniară $g(x) = -5e^{2x} + \cos x - 1$. Să se aproximeze cu un polinom de gradul 3 funcția g după modelul descris în Exemplul 3 pentru punctele $y_1 = -1, y_2 = -1/2, y_3 = 0, y_4 = 1/2$ și $y_5 = 1$. Să se rezolve problema de optimizare cu ajutorul funcțiilor `fminunc` și `quadprog`.

Problema 3. Fie următoarea problemă de optimizare constrânsă:

$$\begin{aligned} \max_{x \in \mathbb{R}^n} \quad & \frac{1}{2} \|Ax\|^2 \\ \text{s.l.:} \quad & \|x\|_1 \leq 1, \end{aligned}$$

```
subplot(2,1,2); plot(w,angle(H));
axis([0,pi,-pi,pi]); xlabel('w'), ylabel('faza H(w)');
```

2.4 Probleme rezolvate de seminar

2.4.1 Mulțimi și funcții convexe

Problema 1. Fie mulțimea S descrisă de:

$$\begin{aligned} S = \{x \in \mathbb{R}^n : a_i^T x = b_i, \quad c_j^T x \leq d_j, \quad i = 1, \dots, m, j = 1, \dots, p\} \\ = \{x \in \mathbb{R}^n : Ax = b, \quad Cx \leq d\}. \end{aligned}$$

Să se demonstreze că mulțimea este convexă (mulțimile definite de egalități și inegalități liniare, cum este cea din enunț, se numesc *poliedre*).

Rezolvare. Se arată că pentru orice $x_1, x_2 \in S$ și $\alpha \in [0, 1]$ rezultă $\alpha x_1 + (1 - \alpha)x_2 \in S$. Dacă $x_1, x_2 \in S$ atunci avem:

$$\begin{cases} Ax_1 = b, & Cx_1 \leq d \\ Ax_2 = b, & Cx_2 \leq d. \end{cases}$$

Notând $x_\alpha = \alpha x_1 + (1 - \alpha)x_2$, putem finaliza demonstrația prin următoarea observație:

$$\begin{aligned} Ax_\alpha &= \alpha Ax_1 + (1 - \alpha)Ax_2 = \alpha b + (1 - \alpha)b = b \\ Cx_\alpha &= \alpha Cx_1 + (1 - \alpha)Cx_2 \leq \alpha d + (1 - \alpha)d = d. \end{aligned}$$

În acest fel am demonstrat că mulțimea definită anterior este convexă.

Problema 2. Să se demonstreze că următoarele mulțimi se pot defini sub forma unor poliedre:

- (i) $S_1 = \{x \in \mathbb{R}^n : x \geq 0, \|x\|_1 = 1\}$
- (ii) $S_2 = \{x \in \mathbb{R}^n : \|x\|_\infty \leq 1\}$
- (iii) $S_3 = \{x \in \mathbb{R}^n : \|x\|_1 \leq 1\}$.

Rezolvare. : (i) În cazul mulțimii S_1 observăm următoarele echivalențe:

$$S_1 = \left\{ x \in \mathbb{R}^n : x \geq 0, \sum_{i=1}^n x_i = 1 \right\} = \left\{ x \in \mathbb{R}^n : -x \leq 0, \sum_{i=1}^n x_i = 1 \right\} \\ = \{x \in \mathbb{R}^n : -I_n x \leq 0, [1 \dots 1]x = 1\},$$

unde I_n reprezintă matricea identitate de ordin n . Ultima formulare denotă forma poliedrală a mulțimii S_1 .

(ii) De asemenea, în cazul mulțimii S_2 , urmând același raționament:

$$S_2 = \left\{ x \in \mathbb{R}^n : \max_{1 \leq i \leq n} |x_i| \leq 1 \right\} = \{x \in \mathbb{R}^n : |x_i| \leq 1, \forall i = 1, \dots, n\} \\ = \{x \in \mathbb{R}^n : -1 \leq x_i \leq 1 \forall i = 1, \dots, n\} \\ = \{x \in \mathbb{R}^n : -x_i \leq 1, x_i \leq 1, \forall i = 1, \dots, n\} \\ = \left\{ x \in \mathbb{R}^n : \begin{bmatrix} I_n \\ -I_n \end{bmatrix} x \leq \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \right\},$$

obținem o formă poliedrală.

(iii) Pentru a determina forma poliedrică a mulțimii S_3 definim o mulțime poliedrică auxiliară:

$$Q = \left\{ \begin{bmatrix} x^T & t^T \end{bmatrix} \in \mathbb{R}^{2n} : \sum_{i=1}^n t_i = 1, |x_i| \leq t_i \right\}.$$

Mai departe, definim proiecția unei mulțimi poliedrice pe un subspațiu de dimensiuni reduse și folosim această noțiune pentru a studia mulțimea S_3 .

Definiția 3. Fie mulțimea $P = \{x \in \mathbb{R}^{n_1}, y \in \mathbb{R}^{n_2} : Ax + By \leq b\}$, unde $A \in \mathbb{R}^{m \times n_1}, B \in \mathbb{R}^{m \times n_2}, b \in \mathbb{R}^m$. *Proiecția* mulțimii P pe subspațiul variabilelor x este dată de:

$$P_x = \{x \in \mathbb{R}^{n_1} : \exists y \in \mathbb{R}^{n_2}, [x^T \ y^T]^T \in P\}.$$

Proiecția mulțimii Q pe subspațiul variabilelor x conduce la următoarea serie de echivalențe:

$$Q_x = \{x \in \mathbb{R}^n : \exists t \in \mathbb{R}^n \text{ a.i. } \sum_{i=1}^n t_i = 1, |x_i| \leq t_i\} \\ = \{x \in \mathbb{R}^n : \sum_{i=1}^n |x_i| \leq 1\} = \{x \in \mathbb{R}^n : \|x\|_1 \leq 1\} = S_3.$$

Ținând cont că proiecția oricărei mulțimi poliedrice este o mulțime poliedrică, concluzionăm că mulțimea S_3 este de tip poliedric.

Problema 3. Fie mulțimile:

$$(i) \mathcal{L}^n = \left\{ \begin{bmatrix} x \\ t \end{bmatrix} \in \mathbb{R}^{n+1} : \|x\| \leq t \right\} \text{ numit și con Lorentz sau con de ordinul II;}$$

$$(ii) \mathcal{S}_+^n = \{X \in \mathbb{S}^n : X \succeq 0\} \text{ conul semidefinit.}$$

Să se demonstreze că mulțimile precedente sunt conuri auto-duale.

Rezolvare: (i) Din definiția conului dual avem:

$$\mathcal{L}_n^* = \{y \in \mathbb{R}^n : \langle x, y \rangle \geq 0 \forall x \in \mathcal{L}_n\}.$$

Problema se reduce la a demonstra că $\mathcal{L}_n^* = \mathcal{L}_n$, ceea ce este echivalent cu satisfacerea simultană a incluziunilor: $\mathcal{L}_n^{**} \subseteq \mathcal{L}^n$ și $\mathcal{L}^n \subseteq \mathcal{L}^{**}$. Arătăm acum prima incluziune. Fie $y = \begin{bmatrix} y_1 \\ v \end{bmatrix} \in \mathcal{L}_n^*$, atunci pentru

$$\text{orice } x = \begin{bmatrix} x_1 \\ t \end{bmatrix} \in \mathcal{L}_n \text{ avem:}$$

$$\langle x, y \rangle = y_1^T x_1 + vt \geq 0. \quad (2.5)$$

Știind că $x \in \mathcal{L}_n$ atunci $\|x\| \leq t$. Rămâne să demonstrăm că $\|y\| \leq v$. Din ipoteza că (2.5) are loc pentru orice vector $x \in \mathcal{L}_n$, atunci inegalitatea este satisfăcută, de asemenea, pentru un x ales. Alegând $x = \begin{bmatrix} x_1 \\ t \end{bmatrix} = \begin{bmatrix} -\frac{y_1}{\|y_1\|} \\ 1 \end{bmatrix}$ și înlocuind în (2.5) obținem:

$$-\frac{y_1^T y_1}{\|y_1\|} + v = -\|y_1\| + v \geq 0,$$

din care rezultă prima incluziune.

Pentru a doua incluziune, fie $y = \begin{bmatrix} y_1 \\ v \end{bmatrix} \in \mathcal{L}_n, x = \begin{bmatrix} x_1 \\ t \end{bmatrix} \in \mathcal{L}_n$. Din inegalitatea Cauchy-Schwartz $|\langle x, y \rangle| \leq \|x\| \|y\|$ rezultă:

$$y_1^T x_1 + vt \geq -\|y_1\| \|x_1\| + vt \geq -vt + vt = 0,$$

unde în a doua inegalitate am utilizat ipoteza că $x, y \in \mathcal{L}_n$. În concluzie, pentru orice $y \in \mathcal{L}_n$ avem că $y \in \mathcal{L}_n^*$.

(ii) În mod similar, arătăm prin dublă incluziune că $\mathcal{S}_+^n = \mathcal{S}_+^{**}$. Fie $Y \in \mathcal{S}_+^{**}$, atunci $\text{Tr}(YX) \geq 0$. Din următoarele relații:

$$x^T Y x = \text{Tr}(x^T Y x) = \text{Tr}(Y x x^T) = \text{Tr}(Y X) \geq 0,$$

se deduce $Y \in \mathcal{S}_+^n$. Pentru a doua incluziune, presupunem Y, X matrice pozitiv semidefinite. Remarcăm următoarea relație:

$$\text{Tr}(YX) = \text{Tr}(Y V V^T \Delta V) = \text{Tr}(V Y V^T \Delta) \geq 0, \quad (2.6)$$

în care am folosit descompunerea valorilor proprii corespunzătoare matricei X și proprietatea de permutare a funcției matriciale $\text{Tr}(\cdot)$. În concluzie, $Y \in \mathcal{S}_+^n$ datorită relației (2.6), de unde reiese a doua incluziune.

Problema 4. Să se demonstreze că următoarele funcții sunt convexe pe mulțimile specificate:

- (i) $f(x) = -\log x$, $\text{dom} f = (0, \infty)$.
- (ii) $f(x) = \frac{1}{2} x^T Q x + q^T x + r$, $\text{dom} f = \mathbb{R}^n, Q \succeq 0$.
- (iii) $f(x, t) = \frac{x^T x}{t}$, $\text{dom} f = \mathbb{R}^n \times (0, \infty)$.
- (iv) $f(x) = \|Ax - b\|$, $A \in \mathbb{R}^{m \times n}$, $\text{dom} f = \mathbb{R}^n$.
- (v) $f(X) = -\log \det X$, $\text{dom} f = \mathcal{S}_{++}^n$.

Rezolvare: (i) Observăm că funcția $f(x) = -\log x$ satisface condițiile de ordinul II ale convexității:

$$f''(x) = \frac{1}{x^2} > 0 \forall x > 0.$$

(ii) Hessiana funcției $f(x) = \frac{1}{2} x^T Q x + q^T x + r$ este dată de $\nabla^2 f(x) = Q$. Observăm că funcția este convexă deoarece matricea $Q \succeq 0$ (este pozitiv semidefinită).

(iii) În aceeași manieră arătăm că funcția $f(x, t) = \frac{x^T x}{t}$ este convexă pe domeniul $\mathbb{R}^n \times (0, \infty)$. Din definiția Hessienei rezultă:

$$\nabla^2 f(x) = \begin{bmatrix} \frac{2}{t} I_n & -\frac{2x}{t^2} \\ -\frac{2x}{t^2} & \frac{2x^T x}{t^3} \end{bmatrix},$$

unde cu I_n am notat matricea identitate de ordin n . Pentru a determina dacă funcția îndeplinește condițiile de ordinul II ale convexității observăm

că:

$$[u^T v^T] \nabla^2 f(x) \begin{bmatrix} u \\ v \end{bmatrix} = [u^T v^T] \begin{bmatrix} \frac{2}{t} u - \frac{2uv}{t^2} \\ -\frac{2u^T u}{t^2} + \frac{2x^T x v}{t^3} \end{bmatrix} \\ = \frac{2}{t} u^T u - \frac{2u^T x v}{t^2} - \frac{2x^T u v}{t^2} + \frac{2x^T x v^2}{t^3} \\ = \frac{2}{t^3} (t^2 u^T u - 2tu^T x v + x^T x v^2) \\ = \frac{2}{t^3} \|tu - xv\|^2.$$

Ținând cont de domeniul de definiție al funcției, remarcăm că pentru orice vector $\begin{bmatrix} u \\ v \end{bmatrix}$, termenul drept din ultima egalitate este pozitiv. De aici este evidentă proprietatea de pozitiv definire a matricei Hessiene corespunzătoare funcției.

(iv) Deoarece funcția $\|\cdot\|$ este nediferențiabilă în punctul 0, observăm că funcția $f(x) = \|Ax - b\|$ nu este diferențiabilă în punctele x ce satisfac $Ax = b$. Fie două puncte din mulțimea $\text{dom} f$ pentru care $f(x_1) = \|Ax_1 - b\|, f(x_2) = \|Ax_2 - b\|$. Pentru a arăta convexitatea funcției f , notăm $x_\alpha = \alpha x_1 + (1 - \alpha)x_2$ și deducem șirul de relații:

$$f(x_\alpha) = f(\alpha x_1 + (1 - \alpha)x_2) \\ = \|A(\alpha x_1 + (1 - \alpha)x_2) - b\| \\ \leq \|\alpha(Ax_1 - b)\| + \|(1 - \alpha)(Ax_2 - b)\| \\ = \alpha \|Ax_1 - b\| + (1 - \alpha) \|Ax_2 - b\| \\ = \alpha f(x_1) + (1 - \alpha) f(x_2).$$

(v) Fie funcția $f(X) = -\log \det X$, $X \in \mathcal{S}_{++}^n$. Arătăm convexitatea lui f prin intermediul reducerii domeniului acesteia la o dreaptă. Mai exact, folosim următoarea proprietate a funcțiilor convexe: f este convexă dacă funcția scalară ce se obține din restricționarea la o dreaptă este de asemenea convexă (conform Remarca 1). Revenind la funcția matricială, considerăm matricele $X \in \mathcal{S}_{++}^n, D \in \mathcal{S}^n$ și arătăm că funcția scalară $g(t) = f(X + tD)$ este convexă, observând următoarele egalități:

$$g(t) = -\log \det(X + tD) \\ = -\log \det(X^{1/2} X^{1/2} + tD) \\ = -\log \det(X^{1/2} (I_n + tX^{-1/2} D X^{-1/2}) X^{1/2})$$

$$\begin{aligned}
&= -\log(\det X^{1/2} \det(I_n + tX^{-1/2}DX^{-1/2}) \det X^{1/2}) \\
&= -\log(\det X \det(I_n + tX^{-1/2}DX^{-1/2})) \\
&= -\log \det X - \log \det(I_n + tX^{-1/2}DX^{-1/2}).
\end{aligned}$$

Pe de altă parte, știind că pentru orice matrice $A \in \mathcal{S}^n$, cu spectrul $\Lambda(A) = \{\lambda_1, \dots, \lambda_n\}$, transformarea $B = I_n + tA, t \in \mathbb{R}$, modifică spectrul astfel încât $\Lambda(B) = \{1 + t\lambda_1, \dots, 1 + t\lambda_n\}$ și $\det B = \prod_{i=1}^n (1 + t\lambda_i)$. Pentru a aplica această proprietate în șirul de relații precedent, notăm $Z = X^{-1/2}DX^{-1/2}$ având spectrul $\Lambda(Z) = \{\mu_1, \dots, \mu_n\}$. Rescriind $g(t)$, rezultă:

$$\begin{aligned}
g(t) &= -\log \det X - \log \prod_{i=1}^n (1 + t\mu_i) \\
&= -\log \det X - \sum_{i=1}^n \log(1 + t\mu_i).
\end{aligned}$$

Mai departe, observăm că funcția $h(t) = -\log(1 + tu)$ din componența celei anterioare, este convexă, deoarece cea de-a doua derivată satisface:

$$h''(t) = \frac{u}{(1 + tu)^2} \geq 0 \quad \forall u \in \mathbb{R}.$$

Știind că funcția definită de o sumă de funcții convexe este convexă, ajungem la concluzia că $g(t)$ este convexă în t . Deci, $f(X)$ este convexă.

Problema 5. Fie funcția $f: \mathbb{R}^n \rightarrow \mathbb{R}$. Să se determine funcția conjugată $f^*(y)$ pentru următoarele exemple:

- (i) $f(x) = e^x$ (ii) $f(x) = x \log x$
 (iii) $f(x) = \frac{1}{2}x^T Qx, Q \succ 0$ (iv) $f(x) = \log \sum_{i=1}^n e^{x_i}$.

Rezolvare. Definim funcția conjugată corespunzătoare funcției f :

$$f^*(y) = \max_{x \in \text{dom } f} \langle y, x \rangle - f(x).$$

În primele două cazuri monovariabile (i) și (ii), observăm că funcția obiectiv a problemei de maximizare este concavă pe domeniul funcției

f , de aceea condițiile de optimalitate de ordinul I conduc la următoarele expresii:

$$(i) \quad f^*(y) = y \log y - y, \quad (ii) \quad f^*(y) = e^{y-1}.$$

(iii) În acest caz, conjugata funcției f are forma $f^*(y) = \max_{x \in \mathbb{R}^n} y^T x - \frac{1}{2}x^T Qx$. Datorită proprietății de convexitate, observăm că soluția problemei de optimizare este dată de $x^* = Q^{-1}y$. Înlocuind în expresia funcției conjugate rezultă $f^*(y) = y^T Q^{-1}y - \frac{1}{2}y^T Q^{-1}y = \frac{1}{2}y^T Q^{-1}y$.

(iv) Condițiile necesare de optimalitate de ordinul I corespunzătoare problemei de maximizare $\max_{x \in \mathbb{R}^n} \langle y, x \rangle - \log \sum_{i=1}^n e^{x_i}$ se reduc la următoarele relații:

$$\frac{e^{x_i^*}}{\sum_{i=1}^n e^{x_i^*}} = y_i, \quad \forall i = 1, \dots, n. \quad (2.7)$$

Observăm că relația (2.7) este satisfăcută și funcția $f^*(y)$ ia valori finite numai în cazul în care argumentul funcției conjugate satisface $\sum_{i=1}^n y_i = 1, y_i \geq 0$. Presupunând că argumentul y satisface cele două condiții, avem $x_i^* = \log \sum_{i=1}^n e^{x_i^*} + \log y_i$ pentru orice $i = 1, \dots, n$. Substituind în expresia funcției conjugate rezultă:

$$\begin{aligned}
\langle y, x^* \rangle - \log \sum_{i=1}^n e^{x_i^*} &= \sum_{i=1}^n y_i \left(\log \sum_{i=1}^n e^{x_i^*} + \log y_i \right) - \log \sum_{i=1}^n e^{x_i^*} \\
&= \sum_{i=1}^n y_i \log y_i + \log \sum_{i=1}^n e^{x_i^*} \left(\sum_{i=1}^n y_i - 1 \right) = \sum_{i=1}^n y_i \log y_i.
\end{aligned}$$

În concluzie, funcția conjugată $f^*(y)$ este definită de:

$$f^*(y) = \begin{cases} \sum_{i=1}^n y_i \log y_i, & \text{dacă } \sum_{i=1}^n y_i = 1, y_i \geq 0, \\ \infty, & \text{altfel.} \end{cases}$$

Problema 6. Să se demonstreze că următoarea problemă de optimizare este convexă:

$$\begin{aligned}
&\min_{x \in \mathbb{R}^2} f(x) = x_1^2 + x_2^2 \\
&\text{s.l.: } g_1(x) = \frac{x_1}{1 + x_2^2} \leq 0, g_2(x) = e^{x_1 + x_2} - 1 \leq 0 \\
&\quad h(x) = (x_1 - x_2 - 1)^2 = 0.
\end{aligned}$$

Rezolvare. Pentru a arăta convexitatea problemei din enunț:

$$\begin{aligned}
&\min_{x \in \mathbb{R}^2} f(x) \\
&\text{s.l.: } g_1(x) \leq 0, g_2(x) \leq 0, h(x) = 0.
\end{aligned}$$

este suficient să demonstrăm convexitatea funcțiilor f , g_1 și g_2 , și liniaritatea funcției h . Observăm că Hessiana funcției f are forma explicită $\nabla^2 f(x) = I_2 \succ 0$, unde I_2 este matricea identitate de ordinul II. Deci, funcția f este convexă deoarece satisface condiția de convexitate de ordinul II. În cazul funcției g_1 , distingem faptul că inegalitatea $\frac{x_1}{1+x_2^2} \leq 0$ este satisfăcută doar în cazul în care $x_1 \leq 0$. În concluzie, constrângerea $g_1(x) \leq 0$ este echivalentă cu o constrângere liniară (și deci convexă) $x_1 \leq 0$. Pentru inegalitate $g_2(x) \leq 0$, observăm că este echivalentă cu $x_1 + x_2 \leq 0$, i.e. este și aceasta echivalentă cu o constrângere liniară. Similar, pentru egalitatea definită de funcția h , găsim următoarea echivalență între mulțimi:

$$\{x \in \mathbb{R}^2 : h(x) = 0\} = \{x \in \mathbb{R}^2 : x_1 - x_2 = 1\},$$

rezultând o funcție liniară în x . În final, putem rescrie problema sub forma unui QP convex:

$$\begin{aligned}
&\min_{x \in \mathbb{R}^2} x_1^2 + x_2^2 \\
&\text{s.l.: } x_1 \leq 0, \quad x_1 + x_2 \leq 0, \quad x_1 - x_2 = 1.
\end{aligned}$$

Problema 7. Să se demonstreze că următoarea problemă de optimizare este convexă:

$$\begin{aligned}
&\min_{x \in \mathbb{R}^2} f(x) \quad (= -\log(a^T x - b)) \\
&\text{s.l.: } g_1(x) = e^{x^T x} - c \leq 0, g_2(x) = (c^T x - d)^2 - 1 \leq 0 \\
&\quad h(x) = (x_1 + 2x_2)^4 = 0.
\end{aligned}$$

Rezolvare. Pentru a demonstra că o problemă de optimizare este convexă, trebuie să demonstrăm că funcția obiectiv este convexă și mulțimea fezabilă definită de constrângeri este convexă. Pentru funcția $f(x) = -\log(a^T x - b)$ deducem expresia gradientului și a Hessienei:

$$\nabla f(x) = -\frac{1}{a^T x - b}a, \quad \nabla^2 f(x) = \frac{1}{(a^T x - b)^2}aa^T$$

unde avem desigur că $(a^T x - b)^2 > 0$. Dacă notăm $y = a^T x$, observăm că:

$$x^T aa^T x = y^T y = \|y\|_2^2 \geq 0,$$

deci matricea aa^T este pozitiv semidefinită. Drept rezultat, $\nabla^2 f(x) \succeq 0$ peste întregul dom $f = \{x \in \mathbb{R}^n : a^T x - b > 0\}$, i.e. satisface condițiile de convexitate de ordin II și deci funcția obiectiv este convexă. Pentru a arăta că mulțimea constrângerilor este convexă, este suficient să arătăm că funcțiile din constrângerile de egalitate sunt liniare, iar cele din constrângerile de inegalitate sunt convexe. Observăm că constrângerea $h(x) = 0$ este echivalentă cu egalitatea $x_1 + 2x_2 = 0$, a cărei funcție este liniară. Pentru $g_1(x) \leq 0$, observăm că este echivalentă cu $x^T x - 1 \leq 0$. Funcția $x^T x - 1$ este o funcție pătratică, diferențiabilă de două ori, cu Hessiana $2I_2 \succ 0$, deci satisface condițiile de convexitate de ordin II și este implicit convexă. Constrângerea $g_2(x) \leq 0$ este echivalentă cu:

$$-1 \leq (c^T x - d) \leq 1 \Rightarrow \begin{cases} c^T x - d \leq 1 \\ -c^T x + d \leq 1 \end{cases} \Rightarrow \begin{bmatrix} c^T \\ -c^T \end{bmatrix} x + \begin{bmatrix} -d \\ d \end{bmatrix} \leq \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

deci aceasta se reduce la o constrângere de inegalitate unde funcția este liniară și implicit convexă.

Problema 8. Să se determine problema convexă de programare semidefinită ce aproximează următoarea problemă neconvexă:

$$\begin{aligned}
&\max_{x \in \mathbb{R}^n} x^T A^T A x \\
&\text{s.l.: } \|x\|_2 \leq 1,
\end{aligned}$$

unde $A \in \mathbb{R}^{m \times n}$ și $\|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$.

Rezolvare. Reamintim că pentru orice $Q \in \mathbb{R}^{n \times n}$ și $x \in \mathbb{R}^n$, funcția $\text{Tr}(Q)$ satisface relația: $\text{Tr}(x^T Q x) = \text{Tr}(Q x x^T)$. Pe baza acestei relații, problema precedentă se scrie sub următoarea formă echivalentă:

$$\begin{aligned} \max_{X \in \mathbb{R}^{n \times n}} \quad & \text{Tr}(A^T A X) \\ \text{s.l.:} \quad & \text{rang}(X) = 1, \text{Tr}(X) = 1. \end{aligned}$$

Se obține relaxarea convexă prin renunțarea la constrângerea de egalitate neliniară $\text{rang}(X) = 1$. În concluzie, avem următoarea aproximare convexă a problemei de optimizare originală:

$$\begin{aligned} \max_{X \in \mathbb{R}^{n \times n}} \quad & \text{Tr}(A^T A X) \\ \text{s.l.:} \quad & \text{Tr}(X) = 1. \end{aligned}$$

2.5 Probleme propuse

Problema 1. Să se determine care dintre următoarele funcții sunt convexe, concave sau niciuna dintre cele două variante. Să se argumenteze rezultatele obținute.

- (i) $f(x_1, x_2) = 2x_1^2 - 4x_1x_2 - 8x_1 + 3x_2$,
- (ii) $f(x_1, x_2) = x_1e^{-(x_1+3x_2)}$,
- (iii) $f(x_1, x_2) = -x_1^2 - 3x_2^2 + 4x_1x_2 + 10x_1 - 10x_2$,
- (iv) $f(x_1, x_2, x_3) = 2x_1x_2 + 2x_1^2 + x_2^2 + 2x_3^2 - 5x_1x_3$,
- (v) $f(x_1, x_2, x_3) = -2x_1^2 - 3x_2^2 - 2x_3^2 + 8x_1x_2 + 3x_1x_3 + 4x_2x_3$.

Problema 2. Să se determine submulțimea din $\{x \in \mathbb{R} : x > 0\}$ pe care funcția $f(x) = e^{ax^b}$ este convexă. Parametrii a, b satisfac $a > 0, b \geq 1$.

Problema 3. Să se determine în domeniul axei reale în care funcția $f(x) = x^2(x^2 - 1)$ este convexă.

Problema 4. Fie funcțiile convexe $f_1, \dots, f_m : \mathbb{R}^n \rightarrow \mathbb{R}$. Să se demonstreze că următoarele compuneri ale acestora sunt convexe:

Capitolul 3

Metode de ordinul I

3.1 Preliminarii

În acest capitol abordăm probleme neliniare de optimizare neconstrânsă (*unconstrained nonlinear programming* - UNLP):

$$(UNLP) : \min_{x \in \mathbb{R}^n} f(x), \quad (3.1)$$

unde funcția obiectiv f este de două ori diferențiabilă. Conform condițiilor de optimalitate necesare pentru problema (3.1), orice punct de minim local pentru problema (UNLP), x^* , satisface următoarele relații:

$$\nabla f(x^*) = 0, \quad \nabla^2 f(x^*) \succcurlyeq 0.$$

În plus, dacă pentru un punct $y^* \in \text{dom} f$ avem $\nabla f(y^*) = 0$ și $\nabla^2 f(y^*) \succ 0$, atunci y^* este punct de minim local strict pentru problema (UNLP) dată în (3.1).

Condițiile de optimalitate joacă un rol fundamental în dezvoltarea algoritmilor eficienți din domeniul optimizării (vezi [1, 2]). În particular, condițiile de ordinul I etau la baza unei clase relativ largi de metode de ordin I (metode ce folosesc evaluarea funcției și informație de gradient). În cazul convex, găsirea unui punct ce satisface condițiile de optimalitate necesare este echivalentă cu rezolvarea problemei de optimizare originale (deoarece condițiile de ordinul I sunt suficiente). Acest argument furnizează o imagine clară asupra facilităților *optimizării convexe* față de cazurile neconvexe, unde pentru găsirea unui punct minim/maxim *local* este necesară rezolvarea condițiilor de ordinul I și de ordin II. Așa cum se observă din experimentele numerice, deși algoritmi de ordinul

I prezintă o complexitate a iterației foarte scăzută (în comparație cu cei de ordin II) și o convergență accelerată în regiunile îndepărtate de punctul de optim, atunci când algoritmul intră în vecinătatea punctului de optim, viteza acestora scade considerabil. De aceea, găsirea unui punct de optim cu o acuratețe mare este un proces dificil pentru metodele de ordin I. În cazul problemelor de dimensiuni foarte mari, când nu este necesară aflarea punctului de optim cu o acuratețe ridicată, recomandarea principală pentru rezolvarea acestora sunt algoritmi de ordin I datorită complexității reduse a iterațiilor acestora. În continuare, prezentăm principalele metode de ordin I și exemple de funcționare ale acestora.

3.2 Probleme rezolvate de laborator

3.2.1 Metoda Gradient

Metoda gradient se află printre primele și cele mai simple metode dezvoltate în scopul determinării unui punct critic aflat pe o anumită curbă (Cauchy, 1847). În principiu, metoda gradient reprezintă un algoritm de ordin I care generează un șir de puncte (vectori) x_1, x_2, \dots , pornind dintr-un punct inițial ales. Structura esențială a metodei gradient este enunțată în continuare:

Metoda Gradient

1. Se alege punctul inițial x_0 , $k := 0$.
2. Se determină pasul α_k și se actualizează $x_{k+1} = x_k - \alpha_k \nabla f(x_k)$.
3. Dacă criteriul de oprire nu este satisfăcut, atunci se incrementează $k := k + 1$ și se reia pasul 2,

unde $\nabla f(x)$ reprezintă gradientul funcției f în punctul x . Pentru alegerea pasului α_k avem mai multe opțiuni:

(i) Alegerea ideală a pasului α_k la fiecare iterație presupune ca funcția scalară $\phi(\alpha) = f(x_k - \alpha \nabla f(x_k))$ să descrească cât mai mult posibil, i.e.

$$\alpha_k = \arg \min_{\alpha > 0} \phi(\alpha),$$

numită și problema de "line search".

(ii) Desori, în funcție de f , minimizarea lui $\phi(\alpha)$ poate fi foarte dificilă. În acest caz, α_k poate fi găsit prin diverși algoritmi mai simpli de

căutare, ce includ condiții necesare asupra pasului pentru asigurarea unei descreșteri suficiente a funcției. Condițiile Wolfe reprezintă un exemplu elocvent pentru această strategie de "line-search":

1. Se aleg două constante c_1 și c_2 ce satisfac $0 < c_1 < c_2 < 1$

2. Se determină $\alpha_k > 0$ astfel încât:

$$f(x_k - \alpha_k \nabla f(x_k)) \leq f(x_k) - c_1 \alpha_k \nabla f(x_k)^T \nabla f(x_k) \quad (3.2)$$

$$\nabla f(x_k)^T \nabla f(x_k - \alpha_k \nabla f(x_k)) \leq c_2 \nabla f(x_k)^T \nabla f(x_k). \quad (3.3)$$

(iii) Un caz particular des utilizat în practică este "metoda backtracking" ce ajustează dimensiunea pasului α_k pentru ca prima relație Wolfe (3.2) să fie satisfăcută; metoda presupune alegerea unui parametru $\rho \in (0, 1]$ și actualizarea dimensiunii pasului, după cum urmează:

1. Se alege $\alpha_0 > 0, \rho \in (0, 1]$;
2. Cât timp α_k nu satisface prima condiție Wolfe (3.2) iterăm :
 - 2.1. $\alpha_{k+1} = \rho \alpha_k$; $k = k + 1$.

(iv) Pentru funcțiile cu gradient continuu în sens Lipschitz cu o constantă $L > 0$, putem alege pasul α_k constant la fiecare iterație. Dacă aplicăm iterația metodei gradient, din condiția continuității funcțiilor cu gradient Lipschitz avem:

$$f(x_{k+1}) \leq f(x_k) - \alpha_k \left(1 - \frac{L}{2} \alpha_k\right) \|\nabla f(x_k)\|^2,$$

rezultând că trebuie să selectăm $\alpha_k \in (0, \frac{2}{L})$, iar pentru o descreștere optimă a funcției, la fiecare iterație alegem $\alpha_k = \frac{1}{L}$.

În exemplul următor vom implementa metoda gradient pentru prima și a treia dintre opțiunile alegerii pasului α_k , unde criteriul de oprire va fi impus de scăderea termenului $\|\nabla f(x_k)\|$ sub o precizie dată.

Exemplul 15. Fie funcția $f(x) = (x_1 - 2)^4 + (x_1 - 2x_2)^2$. Să se implementeze metoda gradient pentru rezolvarea problemei:

$$\min_{x \in \mathbb{R}^n} f(x), \quad (3.4)$$

în varianta cu pas ideal și cea cu pas ales prin metoda de backtracking.

Rezolvare. Pentru început, vom avea nevoie de două funcții:

```
f=feval_obj(x), g=gradient_obj(x)
```

care să returneze valoarea funcției într-un punct x , respectiv gradientul funcției în acel punct. Din moment ce vom căuta pasul ideal la fiecare iterație a metodei gradient, va fi necesară o funcție ce returnează valoarea funcției $\phi(\alpha) = f(x + \alpha d)$:

```
function f=phi_obj(alpha,x,d)
    f=feval_obj(x+alpha*d);
end
```

Pentru găsirea pasului ideal la fiecare iterație, vom utiliza funcția `fminsearch`. Vom porni de la un punct inițial x_0 , iar condiția de oprire a algoritmului va presupune ca norma gradientului să fie sub o anumită toleranță impusă `eps`. Implementarea algoritmului este dată de următoarea secvență de cod:

```
function xmin=gradient_method(x0,eps)
% Initializam vectori/matrice pentru
% memorarea gradientilor, a punctelor x
% generate de algorit, etc
puncte_gradient=[]; puncte_iteratie=[];
valori_functie=[]; norme_gradienti=[];
%vom utiliza un vector g pentru a stoca gradientul curent
x=x0; g=gradient_obj(x);
while(norm(g)>eps)
    g=gradient_obj(x); puncte_gradient=[puncte_gradient g];
    puncte_iteratie=[puncte_iteratie x];
    valori_functie=[valori_functie; feval_obj(x)];
    norme_gradienti=[norme_gradienti; norm(g)];
    alpha=fminsearch(@(alpha) phi_obj(alpha,x,-g).1);
    x=x-alpha*g
end
xmin=x;
```

```
%Pentru afisarea grafica a rezultatelor,
%avem urmatoarele instructiuni
t=1:length(valori_functie);
figure(1)
hold on
```

```
plot(t,norme_gradienti(t),'k','LineWidth',2);
hold off
figure(2)
hold on
plot(t,valori_functie(t),'k','LineWidth',2);
hold off

%Pentru trasarea liniilor de contur si evolutia
%metodei gradient, avem urmatoarele
%instructiuni
[x1,x2]=meshgrid([1.2:0.01:2.8],[0.4:0.01:1.6]);
z=(x1-2).^4+(x1-2.*x2).^2;
figure(3)
hold on
contour(x1,x2,z,valori_functie);
plot3(puncte_iteratie(1,:),puncte_iteratie(2,:),...
valori_functie,'r');
scatter3(puncte_iteratie(1,:),puncte_iteratie(2,:),...
valori_functie,'filled');
hold off
```




Figura 3.1: Convergența metodei gradient cu pas ideal.

Apelarea funcției precedente se face în linia de comandă din Matlab, e.g.:
`xmin=gradient_method([1.4;0.5],0.0001)`

Pentru varianta metodei gradient cu pasul determinat de metoda de backtracking, se poate înlocui în cod funcția `fminsearch` cu următoarea secvență de cod:

```
function alpha=backtrack_alpha(x,d)
    alpha=1; t1=0.9; t2=0.2;
    g=gradient_obj(x);
    %Va trebui satisfacuta conditia Armijo:
    while(feval_obj(x+alpha*d)>feval_obj(x)+t1*alpha*g'*d)
        alpha=alpha*t2;
    end
```

care va fi apelată cu $d = -g = -\nabla f(x)$.

În Fig. 3.1 se observă caracteristica elocventă a metodei gradient care a fost precizată în secțiunile anterioare, și anume decelerarea ratei de convergență pe măsură ce algoritmul se apropie de punctul de optim. În plus, Fig. 3.2 redă rezultatele grafice comparative ale convergenței metodei gradient când criteriul de oprire este de forma $f(x_k) - f^*$ sau $\|\nabla f(x_k)\|$. Observăm că deși criteriul $f(x_k) - f^*$ reflectă mult mai bine acuratețea punctului curent, acesta este rar folosit în practică, deoarece valoarea optimă nu se cunoaște a priori.




Figura 3.2: Comparația convergenței variantelor metodei gradient (cu criteriul $f(x_k) - f^*$ în prima figură și cu criteriul $\|\nabla f(x_k)\|$ în a doua), pentru pas ideal (linie continuă) și pas obținut prin backtracking (linie punctată).

În exemplul următor, vom implementa metoda gradient cu pas constant pentru o funcție pătratică cu gradient Lipschitz, pentru care $L = \lambda_{\max}(Q)$.

Exemplul 16. Fie funcția pătratică:

$$f(x) = \frac{1}{2}x^T \begin{bmatrix} 2.04 & -2.8 & 3.3 \\ -2.8 & 6 & -4 \\ 3.3 & -4 & 17.25 \end{bmatrix} x + [1 \quad -1 \quad -2]x$$




Figura 3.3: Progresul metodei gradient pornind dintr-un punct inițial ales aleatoriu, spre punctul de optim.

Să se implementeze metoda gradient pentru rezolvarea problemei:

$$\min_{x \in \mathbb{R}^3} f(x).$$

Rezolvare. Implementarea metodei gradient din cerința precedentă este dată de următoarea secvență de cod:

```
function [x,f,iter]=gradient(eps)
Q=[2.04 -2.8 3.3;...
-2.8 6 -4;...
3.3 -4 17.25];
q=[1;-1;-2];

L=max(eig(Q)); x=rand(3,1);
grad=Q*x+q;
f_new=0.5*x'*Q*x+q'*x; f_old=f_new+1; iter=0;

while ((f_old-f_new)>eps)
    f_old=f_new; x=x-(1/L)*grad;
    grad=Q*x+q; f_new=0.5*x'*Q*x+q'*x;
    iter=iter+1;
end
f=f_new;
end
```

Să se rezolve sistemul $Qx = -q$ și să se compare soluția acestuia cu cea a problemei anterioare. Să se comenteze observațiile făcute.

3.2.2 Metoda gradientilor conjugați

Metoda gradientilor conjugați face parte, de asemenea, din clasa metodelor de optimizare de ordinul I și reprezintă o metodă iterativă cu performanțe deosebite în rezolvarea problemelor pătratice. A fost dezvoltată de către Hestenes și Stiefel în 1951, în scopul rezolvării sistemelor de ecuații liniare de mari dimensiuni. Deoarece orice problemă de rezolvare a unui sistem de ecuații liniare/nelinare se poate transforma într-o problemă de optimizare pătratică, metoda gradientilor conjugați este considerată o metodă de optimizare. Vom observa că iterația are aproximativ aceeași complexitate ca și cea a metodei gradient, însă folosește un alt raționament pentru a converge la punctul de optim.

Metoda gradientilor conjugați

1. Se alege $\alpha_0 > 0$, x_0 și se calculează $d_0 = -\nabla f(x_0)$.
2. Se actualizează șirurile $x_{k+1} = x_k + \alpha_k d_k$ și $d_{k+1} = -r_{k+1} + \beta_k d_k$.
3. Dacă criteriul de oprire nu este satisfăcut, atunci se incrementează $k = k + 1$ și se reia pasul 2,

unde $\nabla f(x)$ reprezintă gradientul funcției f în punctul x , iar $r_k = \nabla f(x_k)$. Parametrii α_k și β_k sunt definitorii pentru metoda direcțiilor conjugate, variantele de alegere a acestora reprezentând elemente fundamentale ale dezvoltării de noi metode de direcții (gradienti) conjugate (conjugați). Cea mai des folosită variantă a metodei de direcții conjugate pentru funcții pătratice este dată de

$$\alpha_k = -\frac{r_k^T d_k}{d_k^T \nabla^2 f(x_k) d_k}, \quad \beta_k = \frac{r_{k+1}^T \nabla^2 f(x_k) d_k}{d_k^T \nabla^2 f(x_k) d_k}$$

Exemplul 17. Să se determine punctul de optim și valoarea optimă a funcției pătratice $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ definită de:

$$f(x) = 4.5x_1^2 + 5x_2^2 + 3x_1x_2 - 2x_1 - x_2,$$

utilizând metoda gradientilor conjugați cu punctul inițial $x_0 = [0 \ 0]^T$.

Rezolvare. Rescriem funcția f în formă matriceală:

$$f(x) = \frac{1}{2}x^T Qx + q^T x,$$

unde $Q = \begin{bmatrix} 9 & 3 \\ 3 & 10 \end{bmatrix}$, $q^T = [-2 \ -1]$. Cunoaștem că pentru a rezolva probleme pătratice de dimensiune n cu ajutorul metodei gradientilor conjugați sunt necesare n iterații ale acestei metode. De aceea, problema din enunț poate fi rezolvată în două iterații de această metodă. Având la dispoziție gradientul $\nabla f(x_0)$ și direcția d_0 , putem calcula:

$$\alpha_0 = -\frac{\nabla f(x_0)^T d_0}{d_0^T Q d_0}.$$

Prima iterație din șirul x_k al metodei de gradienti conjugați se calculează pe baza informației acumulate până în momentul $k = 1$:

$$x_1 = x_0 + \alpha_0 d_0.$$

La a doua și ultima iterație, pentru calculul lui x_2 avem nevoie de direcția $d_1 = -\nabla f(x_1) + \beta_0 d_0$, unde $\beta_0 = \frac{\nabla f(x_1)^T Q d_0}{d_0^T Q d_0}$. În final, pentru calculul lui x_2 este necesar parametrul $\alpha_1 = -\frac{\nabla f(x_1)^T d_1}{d_1^T Q d_1}$ și rezultă:

$$x_2 = x_1 - \alpha_1 d_1.$$

Deoarece metoda gradientilor conjugați are nevoie de două iterații în cazul nostru, iterația x_2 reprezintă soluția problemei de minimizare. Știind că soluția problemei satisface, de asemenea, și sistemul liniar de ordin II:

$$Qx + q = 0,$$

obținem și un criteriu de verificare pentru soluția returnată de algoritmul de gradienti conjugați. O implementare în cod Matlab este dată de următoarea secvență:

```
function [x f]=conjugate()
Q=[9 3;3 10]; q=[-2;-1];
x=[0;0]; f_new=0.5*x'*Q*x+q'*x;
f=f_new+1; grad=Q*x+q;

iter=0; d=-grad;
while (iter<2)
f=f_new; alpha=-(grad'*d)/(d'*Q*d);
x=x+alpha*d; grad=Q*x+q;
beta=(grad'*Q*d)/(d'*Q*d);
```

```
d=-grad+beta*d; f_new=0.5*x'*Q*x+q'*x;
iter=iter+1;
end
f=f_new;
end
```

Experimentele numerice au condus la concluzia că pentru o funcție pătratică convexă $f: \mathbb{R}^n \rightarrow \mathbb{R}$, metoda gradientilor conjugați converge în n iterații. Observăm un comportament deosebit al acestei metode, deoarece în general, majoritatea metodelor cunoscute converg într-un număr infinit de iterații.

3.3 Probleme rezolvate de seminar

3.3.1 Aproximări pătratice

Problema 1. Fie funcția $f: \mathbb{R}^2 \rightarrow \mathbb{R}$, $f(x) = \frac{1}{2}(x_1^2 + x_2^2)e^{(x_1^2 - x_2^2)}$.

- (i) Să se verifice că punctul $x^* = [0 \ 0]^T$ este un punct de minim local.
- (ii) Să se evalueze gradientul și Hessiana în punctul $x_0 = [1 \ 1]^T$ și să se verifice că Hessiana nu este pozitiv definită. Să se arate că $\nu = 3$ este valoarea întreagă minimă pentru care $H = \nabla^2 f(x_0) + \nu I \succ 0$.
- (iii) Fie punctul $x_0 = [1/2 \ 0]^T$. Să se scrie aproximarea pătratică uzuală (serie Taylor) a acestei funcții în jurul lui x_0 și o aproximare pătratică utilizând în locul Hessiane o matrice $\frac{1}{\beta}I$, cu $\beta > 0$. Minimizați ambele aproximări.

Rezolvare. (i) Gradientul și Hessiana funcției vor fi:

$$\nabla f(x) = e^{(x_1^2 - x_2^2)} \begin{bmatrix} x_1^3 + x_1(1 + x_2^2) \\ -x_2^3 + x_2(1 - x_1^2) \end{bmatrix}$$

$$\nabla^2 f(x) = e^{(x_1^2 - x_2^2)} \begin{bmatrix} 2x_1^2 + x_1^2(5 + 2x_2^2) + x_2^2 + 1 & -2x_1x_2(x_1^2 + x_2^2) \\ -2x_1x_2(x_1^2 + x_2^2) & 2x_2^2 + x_2^2(2x_1^2 - 5) - x_1^2 + 1 \end{bmatrix}.$$

Evident, pentru $x^* = 0$ este punct de minim local deoarece satisface condițiile suficiente de optimalitate:

$$\nabla f(x^*) = 0, \quad \nabla^2 f(x^*) = I_2 \succ 0.$$

(ii) Pentru $x_0 = [1 \ 1]^T$ avem:

$$\nabla f(x_0) = \begin{bmatrix} 3 \\ -1 \end{bmatrix}, \quad \nabla^2 f(x_0) = \begin{bmatrix} 12 & -4 \\ -4 & -1 \end{bmatrix},$$

de unde rezultă că valorile proprii ale lui $\nabla^2 f(x_0)$ sunt $\lambda_{1,2} = \frac{11 \pm \sqrt{25}}{2} \approx (13.13, -2.13)$, i.e. matricea nu este pozitiv definită. Mai mult, observăm că $(\nabla^2 f(x^0) + \nu I) \succ 0$ pentru $\nu = 3 > \lambda_2 \approx -2.13$.

(iii) Pentru punctul $x_0 = [1/2 \ 0]^T$ vom avea:

$$\nabla f(x_0) = e^{\frac{1}{4}} \begin{bmatrix} \frac{3}{8} \\ 0 \end{bmatrix}, \quad \nabla^2 f(x_0) = e^{\frac{1}{4}} \begin{bmatrix} \frac{19}{8} & 0 \\ 0 & \frac{3}{4} \end{bmatrix}.$$

Aproximarea în serie Taylor a funcției în jurul punctului $x_0 = [1/2 \ 0]^T$ va fi:

$$f(x) \approx f(x_0) + \nabla f(x_0)^T (x - x_0) + \frac{1}{2}(x - x_0)^T \nabla^2 f(x_0) (x - x_0)$$

$$= e^{\frac{1}{4}} \left(\frac{19}{16}x_1^2 + \frac{3}{4}x_2^2 - \frac{9}{16}x_1 + \frac{9}{64} \right),$$

al cărei punct de minim este dat de $x_1^N = [9/38 \ 0]^T$. Aproximarea cu $\frac{1}{\beta}I$ are următoarea formă:

$$f(x) \approx f(x_0) + \nabla f(x_0)^T (x - x_0) + \frac{1}{2}(x - x_0)^T \frac{1}{\beta} I_2 (x - x_0)$$

care în acest caz este dată de:

$$f(x) \approx \frac{1}{8}e^{\frac{1}{4}} + e^{\frac{1}{4}} \left[\frac{5}{8} \ 0 \right] \begin{bmatrix} x_1 - \frac{1}{2} \\ x_2 \end{bmatrix} + \frac{1}{2\beta} \begin{bmatrix} x_1 - \frac{1}{2} & x_2 \end{bmatrix}^T I_2 \begin{bmatrix} x_1 - \frac{1}{2} \\ x_2 \end{bmatrix}$$

$$= \frac{1}{8}e^{\frac{1}{4}} + \frac{1}{2\beta} \left((x_1 - \frac{1}{2})^2 + x_2^2 \right) + \frac{5}{8}e^{\frac{1}{4}} \left(x_1 - \frac{1}{2} \right),$$

de unde rezultă punctul de minim $x_1^G = [-\frac{5\beta}{8}e^{\frac{1}{4}} + \frac{1}{2} \ 0]^T$. Observăm că putem alege $\beta = \frac{8}{19e^{\frac{1}{4}}}$ astfel încât $x_1^G = x_1^N$, iar $f(x_1^N) = f(x_1^G)$. În cazul general însă, obținem puncte x_1^G și x_1^N pentru care $f(x_1^G) > f(x_1^N)$.

3.3.2 Condiții de optimalitate de ordin I

Problema 2. Rezolvați problema de maximizare:

$$\max_{x,y} f(x,y) = \frac{1}{(x-a)^2 + (y-a)^2 + 1}.$$

Să se discute rezultatul în funcție de a .

Rezolvare. Prin aplicarea condițiilor suficiente de ordin I, i.e. $\nabla f(x, y) = 0$, obținem sistemul:

$$\begin{cases} \frac{\partial f}{\partial x} = 0 \\ \frac{\partial f}{\partial y} = 0 \end{cases}$$

Explicitând cele două ecuații, obținem:

$$\begin{cases} x - a = 0 \\ y - a = 0. \end{cases}$$

În concluzie, există un singur punct critic dat de perechea (a, a) . Mai departe, demonstrăm că punctul critic este punct de maxim. Verificăm condițiile suficiente de ordin II, i.e. Hessiana $\nabla^2 f(x)$ în punctul (a, a) este o matrice negativ definită,

$$\nabla^2 f(a, a) = \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix}.$$

și constatăm că punctul (a, a) este punct de maxim, indiferent de valoarea parametrului a .

Problema 3. Fie funcția $f(x_1, x_2) = 11x_1^2 + 20x_1x_2 + \alpha x_2^2 - 2x_1 - 2x_2 + 2$.

(i) Să se discute care sunt punctele de minim locale în funcție de α .

(ii) Pentru ce valori ale lui α , funcția are valoarea minimă egală cu 2?

Rezolvare. (i) Observăm că $f(x_1, x_2)$ este funcție pătratică:

$$\begin{aligned} f(x_1, x_2) &= \frac{1}{2}x^T Qx + q^T x + r \\ &= \frac{1}{2} \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 22 & 20 \\ 20 & 2\alpha \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + [-2 \quad -2] \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + 2, \end{aligned}$$

unde $Q = \begin{bmatrix} 22 & 20 \\ 20 & 2\alpha \end{bmatrix}$, $q = \begin{bmatrix} -2 \\ -2 \end{bmatrix}^T$, $r = 2$. Punctele staționare ale funcției f sunt soluții ale sistemului:

$$\nabla f(x_1, x_2) = Qx + q = \begin{bmatrix} 22x_1 + 20x_2 - 2 \\ 20x_1 + 2\alpha x_2 - 2 \end{bmatrix} = 0. \quad (3.5)$$

Un factor ce determină natura punctelor staționare este convexitatea funcției f . Una din modalitățile de verificare a proprietății de convexitate

presupune $\nabla^2 f(x) = Q \geq 0$, pentru orice $x \in \text{dom} f$. Valorile proprii ale matricei Q sunt rădăcinile polinomului caracteristic $\lambda^2 - \lambda(22 + 2\alpha) + 44\alpha + 400 = 0$. Astfel, discutăm convexitatea funcției f după α :

Dacă $\alpha > \frac{100}{11\alpha - 100}$, funcția f este convexă și orice soluție a sistemului (3.5) este un punct de minim global. Rezolvând sistemul, obținem $x_1^* = \frac{1}{11\alpha - 100}(10 - \alpha)$, $x_2^* = \frac{1}{11\alpha - 100}$.

Dacă $\alpha = \frac{100}{11}$ sistemul (3.5) nu are soluție și este definit de ecuațiile:

$$\begin{aligned} 20x_1 + \frac{200}{11}x_2 - 2 &= 0, \\ 22x_1 + 20x_2 - 2 &= 0 \end{aligned}$$

În acest caz, f este convexă, dar nu există punct de minim, i.e. $q \notin \text{Im}(Q)$.

Dacă $\alpha < \frac{100}{11}$, funcția f nu este convexă deoarece matricea Q este indefinită. Punctul critic obținut în acest caz din rezolvarea sistemului (3.5) este punct de inflexiune (staționar).

(ii) Împunem condiția ca punctul (x^*, y^*) să fie punct critic, i.e.

$$\nabla f(x_1, x_2) = 0 \Leftrightarrow \begin{cases} x_1^* = \frac{1}{11\alpha - 100}(10 - \alpha) \\ x_2^* = \frac{1}{11\alpha - 100}. \end{cases}$$

Pentru a determina un punct de minim, ținem cont de condiția de la punctul precedent $\alpha > \frac{100}{11}$. Înlucind valorile lui x_1^* , respectiv x_2^* în

$$f\left(\frac{\alpha - 10}{11\alpha - 100}, \frac{1}{11\alpha - 100}\right) = 2,$$

se determină ușor valoarea scalarului α .

3.3.3 Metoda gradient

Problema 4. Fie funcția $f: \mathbb{R}^2 \rightarrow \mathbb{R}$, $f(x) = \frac{1}{2}\|Ax - b\|_2^2 + 2x^T x$, unde $A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$ și $b = [0 \ 1]^T$. Considerăm de asemenea problema de optimizare aferentă: $\min_{x \in \mathbb{R}^2} f(x)$.

(i) Să se scrie problema de optimizare aferentă ca o problemă QP. Să se calculeze expresia gradientului și Hessiana funcției obiectiv. Să se demonstreze că funcția obiectiv este convexă.

(ii) Să se calculeze punctul de minim global x^* . Pornind din punctul inițial $x_0 = [0 \ 1]^T$, să se implementeze prima iterație x_1 a metodei gradient cu pasul $\alpha_0 = 1$. Să se compare $f(x_0)$, $f(x_1)$ și $f(x^*)$ și să se discute concluzia.

Rezolvare. (i) Pentru a scrie problema anterioară ca o problemă QP, explicităm mai întâi norma din cadrul funcției obiectiv:

$$\begin{aligned} \frac{1}{2}\|Ax - b\|_2^2 &= \frac{1}{2}(Ax - b)^T(Ax - b) \\ &= \frac{1}{2}(x^T A^T Ax - x^T A^T b - b^T Ax + b^T b) \\ &= \frac{1}{2}x^T A^T Ax - (A^T b)^T x + \frac{b^T b}{2} \end{aligned}$$

Formulând $2x^T x$ ca $\frac{1}{2}x^T 4I_2 x$ avem:

$$\min_{x \in \mathbb{R}^2} \frac{1}{2}x^T Qx + q^T x + c$$

unde $Q = A^T A + 4I_2$, $q = -A^T b$ și $c = \frac{1}{2}b^T b$. Se pot determina ușor parametrii:

$$Q = \begin{bmatrix} 6 & 2 \\ 2 & 6 \end{bmatrix}, \quad q = \begin{bmatrix} -1 \\ -1 \end{bmatrix}.$$

Deoarece Q este simetrică, expresia gradientului și a Hessienei sunt definite de:

$$\nabla f(x) = Qx + q = \begin{bmatrix} 6x_1 + 2x_2 - 1 \\ 2x_1 + 6x_2 - 1 \end{bmatrix} \quad \text{și} \quad \nabla^2 f(x) = Q$$

Funcția f este de două ori diferențiabilă, deci putem folosi condiția de ordin II pentru a arăta convexitatea. Mai exact, verificăm dacă $\nabla^2 f(x) \geq 0$ pentru orice $x \in \text{dom} f$. Valorile proprii ale matricei Q sunt soluții ale polinomului caracteristic:

$$\lambda^2 - 12\lambda + 32 = 0,$$

date de $\lambda_{1,2} = \{8, 4\}$, i.e. matricea Q este pozitiv definită.

(ii) Funcția f este convexă, deci condițiile de optimalitate de ordin I sunt suficiente pentru a determina punctul de optim:

$$\nabla f(x^*) = Qx^* + q = 0.$$

Evident, soluția $x^* = -Q^{-1}q$ este determinată de $Q^{-1} = \frac{1}{32} \begin{bmatrix} 6 & -2 \\ -2 & 6 \end{bmatrix}$ rezultând:

$$x^* = \frac{1}{32} \begin{bmatrix} 6 & -2 \\ -2 & 6 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \frac{1}{32} \begin{bmatrix} 4 \\ 4 \end{bmatrix} = \begin{bmatrix} \frac{1}{8} \\ \frac{1}{8} \end{bmatrix}$$

Implementarea primei iterații a metodei gradient presupune calculul vectorului $\nabla f(x_0)$:

$$\nabla f(x_0) = Qx_0 + q = \begin{bmatrix} 1 \\ 5 \end{bmatrix}.$$

Astfel, iterația x_1 rezultă:

$$x_1 = x_0 - \alpha_0 \nabla f(x_0) = \begin{bmatrix} 0 \\ -4 \end{bmatrix}$$

Observăm că $f(x_1) = 52$ și $f(x^*) = -\frac{1}{8}$, deci x_1 se află într-o regiune relativ îndepărtată a optimului x^* . În plus, remarcăm că valoarea funcției în x_1 este mai mare față de cea în x_0 , i.e. $f(x_0) = 2$. Reamintim că aplicarea metodei gradient unei probleme cu funcția obiectiv cu gradient continuu în sens Lipschitz (cu constanta L) presupune alegerea pasului $\alpha \in (0, \frac{1}{L})$. În particular, $L = \lambda_{\max}(Q) = 8$ și conform teoriei $\alpha_0 \in (0, 0.25]$; deci, $\alpha_0 = 1$ ales anterior este inadecvat.

Problema 5. Fie funcția $f: \mathbb{R}^2 \rightarrow \mathbb{R}$, $f(x) = 4x_1^2 + 3x_2^2 - 4x_1x_2 + x_1$, punctul inițial $x_0 = [-\frac{1}{8} \ 0]^T$ și direcția $d_0 = [-\frac{1}{8} \ \frac{2}{5}]^T$.

(i) Este d_0 o direcție de descreștere?

(ii) Notând $\phi(\alpha) = f(x_0 + \alpha d_0)$, să se găsească valoarea $\phi'(1)$.

(iii) Să se calculeze prima iterație x_1 a metodei gradient (cu alegere ideală a dimensiunii pasului).

Rezolvare. (i) Pentru ca direcția d_k să fie direcție de descreștere, trebuie să satisfacă inegalitatea $\nabla f(x_k)^T d_k < 0$. Din expresia gradientului funcției f :

$$\nabla f(x) = \begin{bmatrix} 8x_1 - 4x_2 + 1 \\ 6x_2 - 4x_1 \end{bmatrix},$$

care în punctul x_0 este $\nabla f(x_0) = [0 \ 1/2]^T$, observăm că $\nabla f(x_0)^T d_0 = -1/5$. Deci direcția d_0 este direcție de descreștere.

(ii) Pentru calculul derivatei lui $\phi(\alpha)$ rescriem f sub formă:

$$f(x) = \frac{1}{2}x^T Qx + q^T x, \quad \text{unde } Q = \begin{bmatrix} 8 & -4 \\ -4 & 6 \end{bmatrix} \text{ și } q = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Explicităm $\phi(\alpha)$:

$$\phi(\alpha) = \frac{\alpha^2}{2} d_0^T Q d_0 + \alpha(Qx_0 + q)^T d_0 + \frac{1}{2} x_0^T Q x_0 + q^T x_0,$$

și deducem derivata în 1:

$$\phi'(1) = d_0^T Q d_0 + (Qx_0 + q)^T d_0 = 0.44.$$

(iii) Substituind valorile parametrilor din enunț, problema găsirii dimensiunii ideale a pasului metodei gradient se reduce la minimizarea unei funcții scalare pătratică convexe. Rezultă astfel $\min_{\alpha \geq 0} \phi(\alpha) = -0.0833$

și $\alpha^* = \arg \min_{\alpha \geq 0} \phi(\alpha) = 0.1667$. În final, calculăm prima iterație a metodei gradient:

$$x_1 = x_0 - \alpha^* \nabla f(x_0) = \begin{bmatrix} -0.1250 \\ -0.0833 \end{bmatrix}.$$

Problema 6. Fie problema de minimizare:

$$\min_{x \in \mathbb{R}^2} f(x) \quad (:= 5x_1^2 + 5x_2^2 - x_1x_2 - 11x_1 + 11x_2 + 11).$$

(i) Să se găsească punctele critice.

(ii) Să se demonstreze că un punct ce satisface condițiile de ordin I este, de asemenea, punct de minim global.

(iii) Care este rata de descreștere a metodei gradient pentru această funcție?

(iv) Pornind din punctul inițial $\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$, câte iterații sunt necesare pentru ca algoritmul să atingă acuratețea 10^{-6} ?

Rezolvare. (i) Punctele critice reprezintă soluțiile sistemului $\nabla f(x) = 0$ descris de:

$$\begin{cases} 10x_1 - x_2 - 11 = 0 \\ -x_1 + 10x_2 + 11 = 0. \end{cases}$$

Observăm că sistemul are o singură soluție dată de perechea $(x_1, x_2) = (1, -1)$.

(ii) Observăm că funcția f în forma:

$$f(x_1, x_2) = \frac{1}{2} \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 10 & -1 \\ -1 & 10 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + [-11 \quad 11] \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + 11.$$

are Hessiana pozitiv definită în orice punct al domeniului, i.e.

$$\nabla^2 f(x_1, x_2) = \begin{bmatrix} 10 & -1 \\ -1 & 10 \end{bmatrix} = Q \succ 0.$$

În concluzie, punctul critic $(x_1^*, x_2^*) = (1, -1)$ este punct de minim global.

(iii) Pentru calculul ratei de descreștere corespunzătoare metodei gradient explicităm iterația acesteia:

$$\begin{aligned} x_{k+1} &= x_k - \alpha_k \nabla f(x_k) \\ &= x_k - \alpha_k (Qx_k + q) \\ &= x_k - \alpha_k Qx_k - \alpha_k q \\ &= (I_2 - \alpha_k Q)x_k - \alpha_k q, \end{aligned}$$

unde cu I_2 am notat matricea identitate de ordin II. Considerăm metoda gradient cu pasul constant dat de $\alpha_k = \frac{1}{L}$, unde L reprezintă constanta de continuitate Lipschitz a gradientului funcției obiectiv.

Reamintim acum relația de continuitate în sens Lipschitz a gradientului unei funcții diferențiabile: o funcție $f: \mathbb{R}^n \rightarrow \mathbb{R}$ are gradientul continuu Lipschitz cu constanta L dacă

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|, \forall x, y \in \mathbb{R}^n.$$

În cazul funcției din enunț, relația se reduce la:

$$\|Qx - Qy\| \leq \|Q\|\|x - y\|, \forall x, y \in \mathbb{R}^2,$$

deci putem considera constanta Lipschitz $L = \|Q\| = \lambda_{\max}(Q)$, unde $\lambda_{\max}(Q)$ reprezintă valoarea proprie maximă a lui Q . Observând că în cazul nostru $\lambda_{\max}(Q) = L = 11$, considerăm pasul constant $\alpha_k = \frac{1}{11}$.

Folosind notația $x^* = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$, din condițiile de ordinul I avem $Qx^* = -q$,

de aceea putem reformula iterația în următorul mod:

$$\begin{aligned} x_{k+1} - x^* &= x_k - \frac{1}{11}(Qx_k + q) - x^* \\ &= x_k - \frac{1}{11}(Qx_k - Qx^*) - x^* \\ &= \left(I_2 - \frac{1}{11}Q\right)(x_k - x^*) \\ &\vdots \\ &= \left(I_2 - \frac{1}{11}Q\right)^k (x_0 - x^*). \end{aligned}$$

De aici se poate deriva ușor rata de descreștere a metodei gradient:

$$\begin{aligned} \|x_{k+1} - x^*\| &= \left\| \left(I_2 - \frac{1}{11}Q\right)^k (x_0 - x^*) \right\| \\ &\leq \left\| \left(I_2 - \frac{1}{11}Q\right)^k \right\| \|x_0 - x^*\| \\ &= \|I_2 - \frac{1}{11}Q\|^k \|x_0 - x^*\|. \end{aligned}$$

În concluzie, metoda gradient are rata de descreștere liniară (pentru funcția din enunț) cu factorul $\|I_2 - \frac{1}{11}Q\|$.
(iv) Din punctul anterior, avem rata de convergență a șirului generat de metoda gradient cu pas constant:

$$\|x_k - x^*\| \leq \|I_2 - \frac{1}{11}Q\|^k \|x_0 - x^*\|. \quad (3.6)$$

Calculând norma Euclidiană (norma 2), avem:

$$\left\| I_2 - \frac{1}{11}Q \right\| = \left\| \begin{bmatrix} \frac{10}{11} & \frac{1}{11} \\ \frac{1}{11} & \frac{10}{11} \end{bmatrix} \right\| = \frac{2}{11}.$$

Înlocuind în (3.6) inclusiv valorile pentru x_0 și x^* , avem:

$$\|x_k - x^*\| \leq \sqrt{2} \left(\frac{2}{11} \right)^k.$$

Pentru ca șirul x_k să se apropie de punctul de optim x^* cu acuratețea 10^{-6} , trebuie să asigurăm inegalitatea $\sqrt{2} \left(\frac{2}{11} \right)^k \leq 10^{-6}$. În concluzie,

prin extragerea logaritmului din ambele părți, avem nevoie de un număr de iterații:

$$k \geq \frac{\sqrt{2} \log 10^6}{\log 11 - \log 2}$$

Problema 7. Să se determine extremele funcției $f(x_1, x_2) = x_1^2 x_2^2 (a - x_1 - x_2)$. Pentru ce valori ale lui a , funcția f are un punct de maxim global?

Rezolvare. Obținem punctele de extrem ale funcției rezolvând sistemul dat de condițiile de ordin I, i.e. $\nabla f(x_1, x_2) = 0$. Mai exact, sistemul are forma:

$$\begin{cases} 3x_1^2 x_2^2 (a - x_1 - x_2) - x_1^3 x_2^2 = 0 \\ 2x_1^3 x_2 (a - x_1 - x_2) - x_1^3 x_2^2 = 0 \end{cases} \Rightarrow \begin{cases} x_1^2 x_2^2 (3a - 4x_1 - 3x_2) = 0 \\ x_1^3 x_2 (2a - 2x_1 - 3x_2) = 0, \end{cases}$$

de unde putem deduce trei cazuri diferite:

$$\begin{cases} x_1 = 0 \\ x_2 \text{ oarecare} \end{cases} \quad \text{sau} \quad \begin{cases} x_1 \text{ oarecare} \\ x_2 = 0 \end{cases} \quad \text{sau} \quad \begin{cases} 3a - 4x_1 - 3x_2 = 0 \\ 2a - 2x_1 - 3x_2 = 0 \end{cases}.$$

Componentele Hessienei $\nabla^2 f(x_1, x_2)$ vor fi:

$$\begin{aligned} \frac{\partial^2 f}{\partial x_1^2} &= 2x_1 x_2^2 (3a - 6x_1 - 3x_2), & \frac{\partial^2 f}{\partial x_2^2} &= x_1^3 (2a - 2x_1 - 5x_2) \\ \frac{\partial^2 f}{\partial x_1 \partial x_2} &= \frac{\partial^2 f}{\partial x_2 \partial x_1} = x_1^2 x_2 (6a - 8x_1 - 9x_2), \end{aligned}$$

Constatăm că în primele două cazuri, $x_1 = 0$ sau $x_2 = 0$, matricea

$$\nabla^2 f(x_1, x_2) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$$

este nedefinită. Pentru ultimul caz însă, obținem $x_1 = \frac{a}{2}$ și $x_2 = \frac{a}{3}$. Astfel, observăm că:

$$\nabla^2 f \left(\frac{a}{2}, \frac{a}{3} \right) = \begin{bmatrix} -\frac{a^4}{4} & -\frac{a^4}{12} \\ -\frac{a^4}{12} & -\frac{a^4}{12} \end{bmatrix}$$

iar parametrul a condiționează natura punctului critic $(\frac{a}{2}, \frac{a}{3})$. În final, pentru ca acesta să fie un punct de maxim este necesar ca $\nabla^2 f \left(\frac{a}{2}, \frac{a}{3} \right) \leq 0$, i.e. $a \in [-\frac{3}{2}, 0)$.

Problema 8. Fie funcția $f: \mathbb{R}^n \rightarrow \mathbb{R}$ convexă și diferențiabilă. Să se deducă iterația metodei gradient cu pas constant $\alpha = \frac{1}{L}$ prin intermediul aproximării Taylor pătratică cu Hessiana βI_n .

Rezolvare. În orice punct al domeniului acesteia, funcția f se poate aproxima cu o formă pătratică după cum urmează:

$$f(x) \approx f(\bar{x}) + \nabla f(\bar{x})^T(x - \bar{x}) + \frac{\beta}{2}\|x - \bar{x}\|^2,$$

oricare ar fi $\bar{x} \in \text{dom } f$ și $\beta \geq 0$. Precizăm că partea dreaptă a expresiei anterioare se numește *aproximarea pătratică a funcției f în punctul \bar{x} cu Hessiana βI_n* .

Iterația metodei gradient cu pas constant α se deduce din minimizarea, la fiecare pas k , a aproximării pătratică cu Hessiana $\frac{1}{\alpha} I_n$:

$$x_{k+1} = \arg \min_{y \in \mathbb{R}^n} f(x_k) + \nabla f(x_k)^T(y - x_k) + \frac{1}{2\alpha}\|y - x_k\|^2.$$

Observând că se presupune minimizarea unei funcții convexe, determinăm minimul explicit prin intermediul condițiilor de optimalitate de ordin I:

$$\nabla f(x_k) + \frac{1}{\alpha}(y^* - x_k) = 0,$$

de unde în final deducem:

$$x_{k+1} = y^* = x_k - \alpha \nabla f(x_k).$$

3.4 Probleme propuse

Problema 1. Fie funcția $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $f(x) = \frac{1}{2}[x^T x + \frac{1}{2}(a^T x)^2]$. Să se deducă numărul de flopi necesari pentru calcularea următoarelor elemente: $f(x)$, $\nabla f(x)$, $\nabla^2 f(x)$ și $\nabla^2 f(x)d$, unde $d \in \mathbb{R}^n$ este un vector oarecare.

Problema 2. Pentru următoarele funcții determinați toate punctele staționare și verificați dacă acestea sunt puncte de minim local prin utilizarea condițiilor suficiente de optimalitate de ordinul II:

- (i) $f(x) = 3x_1 + \frac{400}{x_1 x_2} + 5x_2$,

Capitolul 4

Metode de ordinul II

4.1 Preliminarii

În acest capitol considerăm, de asemenea, probleme generale de optimizare neconstrânsă de forma (3.1). Dacă metodele de ordinul I expuse în capitolul anterior se bazează pe informația de gradient a funcției obiectiv, în următoarele secțiuni analizăm algoritmi ce fac uz în plus și de informația de ordinul II, și anume matricea Hessiană a funcției obiectiv (vezi [1, 3]). În cele ce urmează prezentăm pe scurt condițiile de optimalitate necesare și suficiente pentru probleme de optimizare fără constrângeri (restricții) (3.1).

Condițiile necesare de optimalitate pentru problemele neconstrânse pot fi enunțate astfel: orice punct de minim local $x^* \in \text{dom } f$ al problemei (3.1) satisface $\nabla f(x^*) = 0$. De asemenea, *condițiile necesare de ordinul II* se pot formula după cum urmează: orice punct de minim local $x^* \in \text{dom } f$ al problemei (UNLP) satisface:

$$\nabla f(x^*) = 0 \quad \text{și} \quad \nabla^2 f(x^*) \succeq 0.$$

Atribuirem o importanță majoră *condițiilor de optimalitate suficiente* de ordinul II deoarece reprezintă o modalitate de verificare a naturii unui punct dat: dacă x^* satisface

$$\nabla f(x^*) = 0 \quad \text{și} \quad \nabla^2 f(x^*) \succ 0,$$

atunci x^* este un punct strict de minim local al problemei (3.1). Intuitiv, dacă algoritmul de ordinul I rezolvă condițiile necesare de ordinul I cu ajutorul informației de gradient, putem argumenta că cei de ordinul II

converg la un punct de minim local ce satisface condițiile de ordinul I și II, utilizând în plus matricea Hessiană a funcției obiectiv. În continuare, prezentăm principalele metode de ordinul II și analizăm comportamentul acestora pe exemple numerice.

Metoda Newton reprezintă una dintre cele mai vechi metode de optimizare, dezvoltată inițial în scopul aproximării iterative a soluțiilor ecuațiilor neliniare. Această metodă utilizează inversa matricei Hessiene a funcției obiectiv pentru o convergență rapidă către un punct de minim local. Principalul dezavantaj al metodei Newton îl reprezintă instabilitatea provocată de anumiți factori (e.g. inițializarea într-o regiune îndepărtată de optim, condiționarea matricei Hessiene). Cu toate acestea, în cazurile bine condiționate când metoda converge, prezintă o convergență mult superioară metodelor de ordinul I. Ideea principală ce stă la baza metodei Newton o reprezintă aproximarea funcției obiectiv: pentru funcția obiectiv f a problemei (3.1), la iterația k se construiește aproximarea pătratică $\hat{f} \approx f$ (aproximarea Taylor de ordinul II) a funcției obiectiv în punctul curent x_k :

$$\hat{f}(x) = f(x_k) + \nabla f(x_k)^T(x - x_k) + \frac{1}{2}(x - x_k)^T \nabla^2 f(x_k)(x - x_k),$$

care se minimizează cu scopul obținerii iterației Newton. Dacă $\nabla^2 f(x_k)$ este pozitiv definită, atunci funcția $\hat{f}(x)$ este convexă. Pe de altă parte, gradientul funcției $\hat{f}(x)$ este dat de:

$$\nabla \hat{f}(x) = \nabla^2 f(x_k)(x - x_k) + \nabla f(x_k),$$

iar minimul funcției $\hat{f}(x)$ va fi atins într-un punct \bar{x} ce satisface $\nabla \hat{f}(\bar{x}) = 0$. Considerând următorul punct x_{k+1} al șirului ca fiind punctul ce anulează gradientul funcției $\hat{f}(x)$, i.e. $\nabla \hat{f}(x_{k+1}) = 0$, implicit vom obține sistemul liniar de ecuații:

$$\nabla^2 f(x_k)(x_{k+1} - x_k) = -\nabla f(x_k), \quad (4.1)$$

de unde rezultă iterația metodei Newton standard:

$$x_{k+1} = x_k - (\nabla^2 f(x_k))^{-1} \nabla f(x_k).$$

Varianța generală a metodei Newton este dată de iterația:

$$x_{k+1} = x_k - \alpha_k (\nabla^2 f(x_k))^{-1} \nabla f(x_k),$$

considerând selectarea pasului α_k prin aceleași moduri ca la metodele de ordinul I: line search (ideal), backtracking sau $\alpha_k = \alpha$ constant. Observăm că metoda Newton standard are dimensiunea pasului unitar constant, i.e. $\alpha_k = 1$.

Dacă funcția f este pătratică strict convexă (i.e. $\nabla^2 f(x) \succ 0$ pentru orice x), atunci metoda Newton converge într-un singur pas către punctul de minim. În general, metoda Newton nu converge decât dacă inițializarea se realizează în vecinătatea punctului de minim. Există două motivații pentru acest comportament: (i) dacă funcția obiectiv f este puternic neliniară atunci \hat{f} este o aproximare inexactă lui f , de aceea există posibilitatea ca $\hat{f}(x_{k+1}) > f(x_k)$; (ii) nu avem garanția că $\nabla^2 f(x_k) \succ 0$ pe parcursul iterațiilor metodei. Mai exact, dacă $\nabla^2 f(x_k) \not\succeq 0$ sau $\det(\nabla^2 f(x_k)) = 0$, atunci este posibil ca $\hat{f}(x)$ să nu aibă punct de minim. Implementarea metodei Newton necesită abordarea a doi factori importanți:

(i) este necesară implementarea unei reguli de alegere a dimensiunii pasului α_k , astfel încât să eliminăm posibilitatea de creștere a funcției obiectiv în punctele depărtate de optim, fapt datorat impreciziei aproximării pătratică. În cazul în care funcția obiectiv nu este convexă, însă problema de minimizare admite o soluție, atunci inversa Hessienei nu este pozitiv definită în mod cert decât în apropierea soluției;

(ii) dacă nu putem asigura ca Hessiana este pozitiv definită în fiecare punct al șirului $\{x_k\}_{k \geq 0}$, o abordare des întâlnită presupune înlocuirea Hessienei cu o matrice Hessiană modificată $G = \epsilon I_n + \nabla^2 f(x) \succ 0$, cu $\epsilon \geq 0$. Menționăm că întotdeauna va exista un ϵ suficient de mare astfel încât $G \succ 0$. Reamintim că cel mai simplu algoritm pentru a verifica dacă o matrice dată este sau nu pozitiv definită este factorizarea Cholesky.

4.2 Probleme rezolvate de laborator

4.2.1 Metoda Newton

Exemplul 18. Să se implementeze metoda Newton cu cele trei variante de alegere a dimensiunii pasului (ideal, backtracking, pas unitar constant) pentru rezolvarea problemei:

$$\min_{x \in \mathbb{R}^2} f(x) = (x_1 - x_2^2)^2 + 3(x_1 - x_2)^4. \quad (4.2)$$




Figura 4.1: Comparația convergenței metodei Newton utilizând cele trei opțiuni pentru selectarea pașilor: ideal (linie continuă), backtracking (linie punctată întreruptă) și pas constant unitar (linie întreruptă) pentru problema (4.2).

Rezolvare. Utilizăm funcții auxiliare ce returnează informații de ordinul I și II:

```
[f,g]=f_obj(x)
H=hess_obj(x).
```

Funcția `f_obj` returnează valoarea $f(x)$ și $\nabla f(x)$ prin variabilele `f,g`, `hess_obj` returnează $\nabla^2 f(x)$ prin variabile `H`. Pentru selectarea pasului ideal, construim funcția:

```
f=alpha_search(alpha,x,d)
```

ce returnează $f(x+\alpha d)$ în `f`. De asemenea, pentru metoda backtracking construim funcția:

```
alpha=alpha_backtrack(x,d).
```

Condiția de oprire va fi aceeași ca și în cazul metodei gradient, anume $\|\nabla f(x_k)\| < \epsilon$, unde $\epsilon > 0$ reprezintă acuratețea dorită. Secvența de cod ce implementează metoda Newton este prezentată în cele ce urmează:

```
function xmin=newton_method(x0,eps)
%initializam vectori/matrice pentru memorarea gradientilor,
%a punctelor x generate de algoritm, etc
puncte_gradient=[];
puncte_iteratie=[];
```

```
valori_functie=[];
norme_gradienti=[];
%vom utiliza un vector g pentru a stoca gradientul curent
%o matrice H pentru a stoca Hessiana curenta
%calculam directia corespunzatoare in d
x=x0;
[f,g]=f_obj(x);
while(norm(g)>eps)
    [f,g]=f_obj(x);
    H=hess_obj(x);
    d=H\g;
    puncte_gradient=[puncte_gradient g];
    puncte_iteratie=[puncte_iteratie x];
    valori_functie=[valori_functie; f];
    norme_gradienti=[norme_gradienti; norm(g)];
    %Aici selectam alpha=1 constant,
    %alpha=fminbnd(...) pentru exact line search,
    %sau alpha=alpha_backtrack(...)
    %pentru metoda de backtracking
    alpha=fminbnd(@(alpha) alpha_search(alpha,x,d),0,1);
    x=x+alpha*d
end
xmin=x;
```

```
%Pentru afisarea grafica a rezultatelor,
%avem urmatoarele instructiuni
t=1:length(valori_functie);
figure(1)
hold on
plot(t,norme_gradienti(t),'k','LineWidth',2);
hold off
figure(2)
hold on
plot(t,valori_functie(t),'k','LineWidth',2);
hold off
```

```
%Pentru trasarea liniilor de contur si evolutia
%metodei gradient, avem urmatoarele instructiuni
[x1,x2]=meshgrid([1.2:0.01:2.8],[0.4:0.01:1.6]);
```




Figura 4.2: Graficul punctelor obținute de metoda Newton cu pas ideal și liniile de contur aferente pentru problema (4.2).

```
z=(x1-2).^4+(x1-2.*x2).^2;
figure(3)
hold on
contour(x1,x2,z,valori_functie)
plot3(puncte_iteratie(1,:),puncte_iteratie(2,:),...
valori_functie,'r')
scatter3(puncte_iteratie(1,:),puncte_iteratie(2,:),...
valori_functie,'filled')
hold off
```

Rezultatele comparative pentru metoda Newton utilizând cele trei opțiuni pentru selectarea pasului pot fi observate în Fig. 4.1. În Fig. 4.2 observăm punctele obținute de metoda Newton și curbele de nivel aferente.

4.2.2 Metode cvasi-Newton

Deși metoda Newton prezintă convergență pătratică, în multe cazuri ea prezintă dezavantaje din punct de vedere al efortului de calcul datorită necesității calculului derivatelor de ordinul I și a rezolvării sistemului de ecuații (4.1) la fiecare iterație. Pentru probleme de dimensiuni mari ce nu pot fi abordate cu metoda Newton au fost dezvoltate metode de tip *cvasi-Newton*. Această clasă de metode presupun înlocuirea matricei Hessiene cu una simetrică pentru care operația de inversare nu este costisitoare. Șirul de matrice rezultat permite evitarea calculului derivatelor de ordinul II și simplifică rezolvarea sistemului de ecuații (4.1) necesar determinării direcției. Un algoritm de tip *cvasi-Newton* este definit de următoarea schemă:

Fie punctul inițial $x_0 \in \text{dom} f$ și matricea inițială $H_0 > 0$. Pentru $k \geq 1$, cât timp criteriul de oprire nu este satisfăcut, iterăm:

1. se calculează direcția cvasi-Newton $d_k = -H_k^{-1} \nabla f(x_k)$;
2. se determină pasul α_k (e.g. prin metoda de backtracking);
3. se calculează următoarea iterație: $x_{k+1} = x_k + \alpha_k d_k$;
4. se calculează o nouă matrice H_{k+1} .

Metodele de tip cvasi-Newton diferă prin regula de actualizare a matricei H_k . Cea mai des utilizată variantă este metoda *Broyden-Fletcher-Goldfarb-Shanno* (sau metoda BFGS pe scurt):

$$H_k = H_{k-1} + \frac{\delta_k \delta_k^T}{\delta_k^T \Delta_k} - \frac{H_{k-1} \Delta_k \Delta_k^T H_{k-1}}{\Delta_k^T H_{k-1} \Delta_k},$$

unde

$$\Delta_k = x_k - x_{k-1}, \delta_k = \nabla f(x_k) - \nabla f(x_{k-1}).$$

O altă versiune a metodei BFGS consideră actualizarea directă a inversei matricei H_k :

$$H_k^{-1} = \left(I - \frac{\Delta_k \Delta_k^T}{\delta_k^T \Delta_k} \right) H_{k-1}^{-1} \left(I - \frac{\delta_k \Delta_k^T}{\delta_k^T \Delta_k} \right) + \frac{\Delta_k \Delta_k^T}{\delta_k^T \Delta_k}.$$

Structura algoritmului cvasi-Newton cu actualizare BFGS este definită de următoarea schemă:

Selectăm un punct inițial $x_0 \in \mathbb{R}^n$, o toleranță $\epsilon > 0$ și o matrice $H_0 \in \mathbb{R}^{n \times n}$ simetrică și pozitiv definită. Cât timp $\|\nabla f(x_k)\| > \epsilon$,

1. calculăm direcția $d_k = -H_k^{-1} \nabla f(x_k)$;
2. calculăm pasul $\alpha_k = \arg \min_{\alpha > 0} f(x_k + \alpha d_k)$;
3. calculăm noua iterație $x_{k+1} = x_k + \alpha_k d_k$ și $\Delta_k = \alpha_k d_k$;
4. evaluăm $\nabla f(x_{k+1})$ și calculăm $\delta_k = \nabla f(x_{k+1}) - \nabla f(x_k)$;
5. calculăm H_{k+1} prin formula BFGS; $k = k + 1$.

O observație importantă este diferența dintre rata de convergență locală a metodei Newton și a metodelor de tip cvasi-Newton. Cu toate că metodele cvasi-Newton prezintă o complexitate per iterație mai mică, rata de convergență este (super)liniară în timp ce metoda Newton prezintă o rată de convergență pătratică locală.

4.3 Probleme rezolvate de seminar

4.3.1 Metoda Newton și metoda BFGS

Problema 1. Fie problema de optimizare

$$\min_{x \in \mathbb{R}^n} f(x)$$

unde $f: \mathbb{R}^n \rightarrow \mathbb{R}$ este pătratică, i.e. $f(x) = \frac{1}{2}x^T Qx + q^T x$. Să se arate că pentru f convexă metoda Newton standard converge într-un singur pas.

Rezolvare. Din condițiile de optimalitate de ordinul I, i.e. $\nabla f(x) = Qx + q = 0$ va rezulta că $x^* = -Q^{-1}q$. Reținem că direcția metodei Newton este $d = -(\nabla f(x))^{-1} \nabla f(x)$, care în cazul pătratic va fi:

$$d = -Q^{-1}(Qx + q) = -x - Q^{-1}q.$$

Astfel, pentru un punct inițial x_0 și un pas $\alpha_0 = 1$, vom avea:

$$x_1 = x_0 + \alpha_0 d_0 = x_0 - x_0 - Q^{-1}q = -Q^{-1}q.$$

Din moment ce f este convexă, va rezulta automat că $\nabla^2 f(x_0) = Q \succeq 0$, iar drept urmare $x_1 = x^*$.

Problema 2. Fie funcția $f: \mathbb{R}^n \rightarrow \mathbb{R}$ convexă și diferențiabilă de două ori. Să se determine expresia iterației metodei Newton standard prin intermediul aproximării Taylor de ordinul II. Este posibilă și o altă modalitate de a obține această iterație?

Rezolvare. Deoarece funcția f este diferențiabilă de două ori, în orice punct al domeniului acesteia $\bar{x} \in \text{dom} f$, se poate aproxima cu o formă pătratică:

$$f(x) \approx f(\bar{x}) + \nabla f(\bar{x})^T(x - \bar{x}) + \frac{1}{2}(x - \bar{x})^T \nabla^2 f(\bar{x})(x - \bar{x}).$$

Precizăm că partea dreaptă a expresiei anterioare se numește *aproximarea Taylor de ordinul II în punctul \bar{x} a funcției f* .

Fie punctul curent x_k al metodei Newton, următoarea iterație x_{k+1} se determină din minimizarea neconstrânsă a aproximării de ordinul II în punctul x_k a funcției obiectiv:

$$x_{k+1} = \arg \min_{y \in \mathbb{R}^n} f(x_k) + \nabla f(x_k)^T(y - x_k) + \frac{1}{2}(y - x_k)^T \nabla^2 f(x_k)(y - x_k).$$

Deoarece funcția f este convexă, matricea $\nabla^2 f(x_k)$ este pozitiv semi-definită, deci aproximarea pătratică este convexă. Determinăm punctul de minim al acestei aproximări din condițiile de optimalitate de ordinul I:

$$\nabla^2 f(x_k)(y^* - x_k) + \nabla f(x_k) = 0,$$

de unde rezultă iterația:

$$x_{k+1} = y^* = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k).$$

O modalitate alternativă de a deduce iterația Newton este descrisă de liniarizarea expresiei gradientului funcției obiectiv în punctul curent x_k :

$$\nabla f(x) \approx \nabla f(\bar{x}) + \nabla^2 f(\bar{x})(y - \bar{x}),$$

unde considerăm $\nabla f(\bar{x})$ și $\nabla^2 f(\bar{x})$ cunoscute. Pentru a obține iterația Newton, la momentul $k + 1$, egalăm cu 0 aproximarea liniară a gradientului, în punctul x_k :

$$\nabla f(x_k) + \nabla^2 f(x_k)(y^* - x_k) = 0,$$

de unde rezultă:

$$x_{k+1} = y^* = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k).$$

Menționăm în plus că iterația metodei Newton generale

$$x_{k+1} = x_k - \alpha_k [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

se obține din minimizarea unei aproximări Taylor pătratice de forma:

$$x_{k+1} = \arg \min_{y \in \mathbb{R}^n} f(x_k) + \nabla f(x_k)^T(y - x_k) + \frac{1}{2\alpha_k}(y - x_k)^T \nabla^2 f(x_k)(y - x_k).$$

De asemenea, iterația metodei gradient $x_{k+1} = x_k - \alpha_k \nabla f(x_k)$ se poate obține dintr-o aproximare pătratică de forma:

$$x_{k+1} = \arg \min_{y \in \mathbb{R}^n} f(x_k) + \nabla f(x_k)^T(y - x_k) + \frac{1}{2\alpha_k} \|y - x_k\|^2.$$

Problema 3. Fie problema de optimizare neconstrânsă:

$$\min_{x \in \mathbb{R}^2} f(x) \quad \left(= \frac{1}{2}x_1^2 + \frac{5}{2}x_2^2 + 2x_1x_2 + 2x_1 + 4x_2 \right).$$

- Să se scrie problema ca o problemă QP (*Quadratic Programming*). Să se arate că problema este convexă.
- Să se determine punctul de minim x^* al problemei.
- Pornind din punctul $x^0 = [1 \ -1]^T$, să se determine pasul optim α_0 corespunzător metodei gradient și să se implementeze prima iterație a acestei metode cu pasul obținut.
- Să se implementeze prima iterație a metodei Newton standard pentru problema precedentă. Să se compare punctul x_1 al metodei gradient cu cel al metodei Newton. Ce se observă?

Rezolvare. (i) Prin rescrierea sub formă matriceală a funcției obiectiv ajungem la forma QP:

$$f(x) = \frac{1}{2}x^T \begin{bmatrix} 1 & 2 \\ 2 & 5 \end{bmatrix} x + \begin{bmatrix} 2 & 4 \end{bmatrix} x.$$

Pentru a determina convexitatea funcției, verificăm dacă matricea Hessiană:

$$\nabla^2 f(x) = Q = \begin{bmatrix} 1 & 2 \\ 2 & 5 \end{bmatrix}$$

este pozitiv semidefinită. Observăm că minorii principali sunt strict pozitivi, rezultând că Hessiana este pozitiv definită.

- Deoarece funcția obiectiv este strict convexă, punctul de minim neconstrâns este dat de condițiile de optimalitate de ordinul I:

$$\nabla f(x^*) = Qx^* + q = 0,$$

unde $q = \begin{bmatrix} 2 \\ 4 \end{bmatrix}$ și de unde rezultă soluția unică $x^* = \begin{bmatrix} -2 \\ 0 \end{bmatrix}$.

- Reamintim procedura de selectare a lungimii ideale a pasului:

$$\alpha_0 = \arg \min_{\alpha \geq 0} \phi(\alpha) = \arg \min_{\alpha \geq 0} f(x_0 - \alpha \nabla f(x_0)). \quad (4.3)$$

Obținând direcția de gradient $d_0 = -\nabla f(x_0) = Qx_0 + q = \begin{bmatrix} -1 \\ -1 \end{bmatrix}$, evaluăm funcția obiectiv:

$$\phi(\alpha) = f(x_0 - \alpha \nabla f(x_0)) = \frac{1}{2} [(1 - \alpha)^2 + 5(1 + \alpha)^2] - 2(1 - \alpha^2) - 6\alpha - 2 = 5\alpha^2 - 2\alpha - 1.$$

Observăm că punctul de minim global neconstrâns al funcției $\phi(\alpha)$ este $\alpha^* = \frac{1}{5}$. Deoarece problema (4.3) este constrânsă, iar punctul de minim neconstrâns α^* se află în mulțimea fezabilă $\{\alpha \in \mathbb{R} : \alpha \geq 0\}$, concluzionăm că lungimea ideală a pasului este $\alpha_0 = \frac{1}{5}$. Prima iterație a metodei gradient cu pas ideal este dată de:

$$x_1^G = x_0 - \alpha_0 \nabla f(x_0) = \begin{bmatrix} \frac{4}{5} \\ \frac{6}{5} \end{bmatrix}.$$

- Metoda Newton standard presupune următoarea iterație:

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k).$$

În cazul nostru, funcția obiectiv este pătratică (implicit de două ori diferențiabilă) cu Hessiana:

$$\nabla^2 f(x) = \begin{bmatrix} 1 & 2 \\ 2 & 5 \end{bmatrix}.$$

Calculăm inversa matricei Hessiene:

$$[\nabla^2 f(x)]^{-1} = \begin{bmatrix} 5 & -2 \\ -2 & 1 \end{bmatrix},$$

iar primul pas al metodei Newton standard este dat de:

$$x_1^N = x_0 - [\nabla^2 f(x_0)]^{-1} \nabla f(x_0) = \begin{bmatrix} 1 \\ -1 \end{bmatrix} - \begin{bmatrix} 5 & -2 \\ -2 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} -2 \\ 0 \end{bmatrix} = x^*.$$

În concluzie, metoda Newton converge pentru această problemă într-un singur pas către punctul de minim.

Problema 4. Fie funcția $f: \mathbb{R}^2 \rightarrow \mathbb{R}$, definită de:

$$f(x_1, x_2) = \frac{x_1^4}{4} + \frac{x_2^4}{4} - \frac{x_1^3}{3} - \frac{x_2^3}{3}.$$

- (i) Să se determine un punct de minim local al problemei:

$$\min_{x \in \mathbb{R}^2} f(x)$$

- (ii) Să se calculeze prima iterație a metodei Newton alegând punctul inițial $x^0 = [-1 \ 1]^T$ și considerând cazurile în care pasul $\alpha_0 = 1$ și α_0 este selectat ideal.

Rezolvare. (i) Calculăm mai întâi expresia gradientului și Hessienei:

$$\nabla f(x) = \begin{bmatrix} x_1^3 - x_2^3 \\ x_2^3 - x_2^2 \end{bmatrix}, \quad \nabla^2 f(x) = \begin{bmatrix} 3x_1^2 - 2x_1 & 0 \\ 0 & 3x_2^2 - 2x_2 \end{bmatrix}.$$

Din condiția $\nabla f(x^*) = 0$ deducem că componentele lui x^* satisfac condiția $x_1^*, x_2^* \in \{0, 1\}$, iar pentru $x^* = [1 \ 1]^T$ avem:

$$\nabla^2 f(1, 1) = I_2 > 0,$$

deci $x^* = [1 \ 1]^T$ este punct de minim strict local.

- (ii) Pentru punctul inițial $x^0 = [-1 \ 1]^T$ avem:

$$\nabla f(x^0) = \begin{bmatrix} -2 \\ 0 \end{bmatrix}, \quad \nabla^2 f(x^0) = \begin{bmatrix} 5 & 0 \\ 0 & 1 \end{bmatrix}, \quad [\nabla^2 f(x^0)]^{-1} = \begin{bmatrix} \frac{1}{5} & 0 \\ 0 & 1 \end{bmatrix},$$

de unde rezultă direcția Newton:

$$d_0 = -[\nabla^2 f(x^0)]^{-1} \nabla f(x^0) = \begin{bmatrix} d_0^1 \\ d_0^2 \end{bmatrix} = \begin{bmatrix} \frac{2}{5} \\ 0 \end{bmatrix}.$$

Acum, pentru determinarea pasului ideal, trebuie să calculăm $\phi(\alpha) = f(x_0 + \alpha d_0)$ pentru funcția noastră obiectiv:

$$\begin{aligned} \phi(\alpha) &= \frac{1}{4}(x_1 + \alpha d_0^1)^4 + \frac{1}{4}(x_2 + \alpha d_0^2)^4 - \frac{1}{3}(x_1 + \alpha d_0^1)^3 - \frac{1}{3}(x_2 + \alpha d_0^2)^3. \\ &= \frac{1}{4}(x_1 + \frac{2\alpha}{5})^4 - \frac{1}{3}(x_1 + \frac{2\alpha}{5})^3 + \frac{x_2^4}{4} - \frac{x_2^3}{3}. \end{aligned}$$

Rezolvăm ecuația $\phi'(\alpha) = 0$, de unde obținem $\alpha^* = 5$. Astfel, pentru pasul $\alpha_0 = 1$, respectiv $\alpha_0 = 5$ iterațiile sunt date de:

$$x_1 = \begin{bmatrix} \frac{3}{5} \\ 1 \end{bmatrix}, \quad x_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} = x^*.$$

Evaluând funcția obiectiv în cele două puncte $f(3/5, 1) = 0.0211$, $f(1, 1) = -0.1667$, constatăm o descreștere mai bună cu dimensiunea ideală a pasului.

Problema 5. Dacă efectuăm o actualizare de rang 1 asupra unei matrice pătrate și nesingulare A și notăm rezultatul cu \bar{A} , i.e.:

$$\bar{A} = A + uv^T,$$

unde $a, b \in \mathbb{R}^n$, atunci formula Sherman-Morrison-Woodbury are loc:

$$\bar{A}^{-1} = A^{-1} - \frac{A^{-1}uv^T A^{-1}}{1 + v^T A^{-1}u}. \quad (4.4)$$

Rezolvare. Pentru a verifica această formulă, conform definiției matricii inverse, avem egalitatea $\bar{A}^{-1}\bar{A} = I_n$. Astfel, simplăm înmulțim pe \bar{A} cu \bar{A}^{-1} :

$$\begin{aligned} \bar{A}^{-1}\bar{A} &= \left(A^{-1} - \frac{A^{-1}uv^T A^{-1}}{1 + v^T A^{-1}u} \right) (A + uv^T) \\ &= I_n + A^{-1}uv^T - \frac{A^{-1}uv^T + A^{-1}u(v^T A^{-1}u)v^T}{1 + v^T A^{-1}u} \\ &= I_n + A^{-1}uv^T - \frac{A^{-1}uv^T + (v^T A^{-1}u)A^{-1}uv^T}{1 + v^T A^{-1}u} \\ &= I_n + A^{-1}uv^T - \frac{1 + v^T A^{-1}u}{1 + v^T A^{-1}u} A^{-1}uv^T = I_n. \end{aligned}$$

Problema 6. Fie funcția $f: \mathbb{R} \rightarrow \mathbb{R}$, definită de $f(x) = (x-1)^2/(x^2+1)$. Să se implementeze metoda Newton pornind din punctele inițiale $x_0 = \{-2, 0, -1\}$. Ce se observă?

Rezolvare. Calculăm mai întâi gradientul funcției și Hessiana:

$$\nabla f(x) = \frac{2(x^2-1)}{(x^2+1)^2}, \quad \nabla^2 f(x) = \frac{4x(3-x^2)}{(x^2+1)^3}.$$

Din condițiile de optimalitate va rezulta desigur că $x^* = 1$ este punct de minim local strict. Utilizând expresiile obținute ale gradientului și Hessienei, deducem expresia direcției Newton:

$$d(x) = -[\nabla^2 f(x)]^{-1} \nabla f(x) = -\frac{x^4-1}{2x(3-x^2)}.$$

Astfel, pentru punctele inițiale avem:

$$d(-2) = \frac{-15}{4}, \quad d(-1) = 0,$$

iar în $x_0 = 0$ avem $\nabla^2 f(0) = 0$ și direcția Newton în acest caz nu există. Observăm că pentru $x_0 = -1$ metoda Newton va rămâne în același punct. Pe de altă parte, pentru $x_0 = 0$ Hessiana nu este inversabilă, iar metoda Newton standard nu poate fi aplicată. Pentru $x_0 = -2$ avem $x_1 = -2-15/4 = -23/4$, iar din expresia direcției deducem că metoda diverge. Observăm că pentru un punct inițial suficient de aproape de punctul de optim, e.g. $x_0 = 1.3$, metoda Newton converge.

Problema 7. Fie funcția $f: \mathbb{R}^2 \rightarrow \mathbb{R}$, definită de $f(x) = x_1^4 + x_1 x_2 + (1 + x_2)^2$. Să se descrie performanțele metodei Newton aplicată problemei:

$$\min_{x \in \mathbb{R}^2} f(x),$$

pornind din punctul inițial $x_0 = [0 \ 0]^T$.

Rezolvare. Calculăm expresiile gradientului și Hessienei:

$$\nabla f(x) = \begin{bmatrix} 4x_1^3 + x_2 \\ x_1 + 2(x_2 + 1) \end{bmatrix}, \quad \nabla^2 f(x) = \begin{bmatrix} 12x_1^2 & 1 \\ 1 & 2 \end{bmatrix}$$

și evaluând aceste expresii în x_0 avem:

$$\nabla f(x^0) = \begin{bmatrix} 0 \\ 2 \end{bmatrix}, \quad \nabla^2 f(x^0) = \begin{bmatrix} 0 & 1 \\ 1 & 2 \end{bmatrix}, \quad (\nabla^2 f(x^0))^{-1} = \begin{bmatrix} -2 & 1 \\ 1 & 0 \end{bmatrix}.$$

Astfel, direcția Newton pentru punctul x_0 va fi:

$$d_0 = -(\nabla^2 f(x_0))^{-1} \nabla f(x_0) = \begin{bmatrix} -2 \\ 0 \end{bmatrix},$$

iar $\nabla f(x_0)^T d_0 = 0$. Observăm că aceeași egalitate este valabilă de asemenea pentru $-d_0$. Astfel, d_0 nu este direcție de descreștere. În plus, observăm că $f(x_0) = 1$, iar pentru $x_1 = x_0 + d_0 = [-2 \ 0]^T$, vom avea $f(x_1) = 17$, iar pentru $x_1 = x_0 - d_0$ vom avea tot $f(x_1) = 17$.

Problema 8. O problemă fundamentală din domeniul prelucrării semnalelor o reprezintă recuperarea unui semnal x dintr-unul corupt y (fiind semnalul adevărat x combinat cu zgomot). De cele mai multe ori, problema este abordată prin aproximarea cât mai fidelă a semnalului adevărat prin intermediul rezolvării următoarei probleme de optimizare:

$$\min_{x \in \mathbb{R}^n} \|x - y\|_2 + \mu \sum_{i=1}^{n-1} |x_{i+1} - x_i|,$$

Observăm că deși primul termen ce denotă distanța Euclidiană dintre semnalul adevărat x și cel corupt y este suficient pentru a găsi o aproximare relativ fidelă, se adaugă un termen de regularizare descris de suma diferențelor dintre elementele consecutive ale semnalului x . Acest termen de regularizare are scopul de a asigura găsirea unei aproximări cât mai netede, fără variații bruște ale componentelor. Observăm că funcția obiectiv a problemei anterioare este nediferențiabilă.

- (i) Să se determine o aproximare a problemei de optimizare precedente, cu funcția obiectiv continuu diferentiabilă;

- (ii) Să se calculeze forma explicită a gradientului și Hessienei corespunzătoare noii funcții obiectiv de la punctul a), și să se aplice un pas al metodei Newton.

Rezolvare. (i) O aproximare netedă (*smooth*) a problemei din enunț este dată de:

$$\min_{x \in \mathbb{R}^n} f(x) \quad \left(= \|x - y\|_2^2 + \mu \sum_{i=1}^{n-1} \left(\sqrt{\epsilon^2 + (x_{i+1} - x_i)^2} - \epsilon \right) \right),$$

unde $\epsilon > 0$ este suficient de mic.

- (ii) Determinăm forma explicită a primului pas din metoda Newton. Reamintim direcția Newton: $dx = -[\nabla^2 f(x)]^{-1} \nabla f(x)$. Notând $\phi_\epsilon(x) = \mu \sum_{i=1}^{n-1} \left(\sqrt{\epsilon^2 + (x_{i+1} - x_i)^2} - \epsilon \right)$, se observă că gradientul funcției obiectiv a problemei de la punctul a) este:

$$\nabla f(x) = 2(x - y) + \mu \nabla \phi_\epsilon(x).$$

Mai departe, Hessiana aceleiași funcții este dată de: $\nabla^2 f(x) = 2I_n + \mu \nabla^2 \phi_\epsilon(x)$. În concluzie, dificultatea se reduce la determinarea formei explicite a gradientului și matricii Hessiene corespunzătoare funcției ϕ_ϵ . Pentru o expunere simplificată, notăm $g(u) = \mu \sum_{i=1}^{n-1} \left(\sqrt{\epsilon^2 + u_i^2} - \epsilon \right)$, și observăm că $\phi_\epsilon(x) = g(Ax)$, unde $A \in \mathbb{R}^{(n-1) \times n}$ dată de:

$$A = \begin{bmatrix} -1 & 1 & 0 & 0 & 0 & 0 \\ 0 & -1 & 1 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & -1 & 1 \end{bmatrix}.$$

Precizăm că sunt suficiente expresiile derivatelor funcției g pentru a le determina pe cele ale funcției ϕ_ϵ . Astfel, determinăm forma explicită a componentelor acestora:

$$\nabla_i g(u) = \frac{u_i}{\sqrt{\epsilon^2 + u_i^2}} \quad \nabla_{ii}^2 g(u) = -\frac{\epsilon^2}{\sqrt{\epsilon^2 + u_i^2}}.$$

Deoarece funcția g este separabilă, Hessiana acesteia este matrice diagonală. În final avem:

$$\nabla f(x) = 2(x - y) + \mu A^T \nabla g(Ax) \quad \nabla^2 f(x) = 2I_n + \mu A^T \nabla^2 g(Ax) A$$

și observăm că matricea $\nabla^2 f(x)$ este superior bidiagonală. Direcția Newton este dată de soluția sistemului superior bidiagonal:

$$\nabla^2 f(x) d_N = -\nabla f(x),$$

ce se rezolvă în $\mathcal{O}(n)$ operații.

4.4 Probleme propuse

Problema 1. Pentru următoarele două probleme, să se determine punctele de optim și să se implementeze primii trei pași ai metodei Newton standard, i.e. cu pas constant $\alpha = 1$:

- (i) $\min_{x \in \mathbb{R}} \ln(e^x + e^{-x})$, pornind din $x_0 = 1$ și $x_0 = 1.1$
- (ii) $\min_{x \in \mathbb{R}} -\ln x + x$, pornind din $x_0 = 3$

Ce se observă după primii trei pași?

Problema 2. Fie următoarea problemă de optimizare:

$$\min_{x \in \mathbb{R}^2} x_1^4 + 100x_2^2$$

Să se implementeze metoda BFGS cu pas optim la fiecare iterație, pornind din punctul inițial $x^0 = [1 \ 1]^T$ și matricea inițială $H_0 = I_2$. În câți pași converge metoda la punctul de optim?

tip simplex, i.e.: $\{x : \sum_{i=1}^n x_i = 1, x_i \geq 0, i = 1, \dots, n\}$.

Problema 3. Să se înlocuiască funcția obiectiv din problema 1 (Probleme rezolvate) cu $\|x\|_\infty$ și să se rezolve noua problemă.

Problema 4. Să se determine sistemul KKT pentru următoarea problemă de optimizare:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} \quad & x_1^2 + x_2^2 \\ \text{s.t.} \quad & (x_1 - 1)^2 + (x_2 - 1)^2 \leq 1, \\ & (x_1 - 1)^2 + (x_2 + 1)^2 \leq 1. \end{aligned}$$

Există multiplicatori Lagrange λ_1^* și λ_2^* care să demonstreze că punctul x^* este optim?

Problema 5. Fie problema de optimizare:

$$\begin{aligned} \min_{x \in \mathbb{R}^3} \quad & x_1^4 + x_2^4 + x_3^4 + (x_1 + 2x_2 - 4)^2 \\ \text{s.t.} \quad & x_1 + x_2 + x_3 = 1, x \geq 0. \end{aligned}$$

Să se scrie primul pas al metodei gradient proiectat, pornind din punctul inițial $x_0 = [1 \ 0 \ 0]^T$ și alegând pasul $s_k = 1$.

Problema 6. Fie problema de optimizare:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} \quad & x_1^4 + x_2^4 + (x_1 - 1)^2 + (x_2 - 4)^2 \\ \text{s.t.} \quad & x_1 + x_2 = 16 \end{aligned}$$

Să se scrie aproximarea Taylor de ordin II pentru funcția obiectiv și să se scrie primul pas al metodei Newton proiectat pornind din punctul inițial $x_0 = [14 \ -2]^T$.

Problema 7. Fie problema de optimizare:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} \quad & x_1^2 + 1 \\ \text{s.t.} \quad & (x - 1)(x - 4) \leq 0 \end{aligned}$$

Să se determine mulțimea fezabilă, punctul de minim și valoarea minimă pentru această problemă. Să se traseze pe același grafic funcția obiectiv,

mulțimea fezabilă, punctul de minim și Lagrangianul $\mathcal{L}(x, \lambda)$ pentru două valori pozitive ale lui λ luate la alegere. Să se formuleze problema duală, să se demonstreze că este concavă și să se găsească punctul optim dual λ^* .

Problema 8. Considerăm problema celor mai mici pătrate cu constrângeri de egalitate:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \|Ax - b\|_2^2 \\ \text{s.t.} \quad & Cx = d \end{aligned}$$

unde $A \in \mathbb{R}^{m \times n}$, $\text{rang}(A) = n$, $C \in \mathbb{R}^{p \times n}$, cu $\text{rang}(C) = p$. Să se explicitizeze condițiile KKT ale acestei probleme și să se determine expresia soluției primale x^* și a celei duale μ^* .

Problema 9. Fie problema de optimizare:

$$\begin{aligned} \min_{x \in \mathbb{R}^3} \quad & -3x_1^2 + x_2^2 + 2x_3^2 + 2(x_1 + x_2 + x_3) \\ \text{s.t.} \quad & x_1^2 + x_2^2 + x_3^2 = 1 \end{aligned}$$

Să se determine punctele punctele KKT pentru această problemă. Care pereche de puncte îi va corespunde punctului de optim?

Problema 10. Fie problema de optimizare:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \sum_{i=1}^n \log(c_i + x_i) \\ \text{s.t.} \quad & x \geq 0, \quad \sum_{i=1}^n x_i = 1, \end{aligned}$$

unde c_i reprezintă parametrii cunoscuți.

- (i) Să se determine problema duală.
- (ii) Să se determine un punct KKT.